

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-182905-116208

Bc. Matej Kandráč

**Inteligentný asistent trénovania
prezentačných schopností**

Diplomová práca

Vedúci práce: Ing. Bahleda Miroslav, PhD.

Máj 2026

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií

FIIT-182905-116208

Bc. Matej Kandráč

**Inteligentný asistent tréningu
prezentačných schopností**

Diplomová práca

Študijný program: Inteligentné softvérové systémy

Študijný odbor: 18. Informatika

Miesto vypracovania: Ústav informatiky, informačných systémov a softvérového
inžinierstva, FIIT STU, Bratislava

Vedúci práce: Ing. Bahleda Miroslav, PhD.

Máj 2026



ZADANIE DIPLOMOVEJ PRÁCE

Študent: **Bc. Matej Kandráč**
ID študenta: 116208
Študijný program: inteligentné softvérové systémy
Študijný odbor: informatika
Vedúci práce: Ing. Miroslav Bahleda, PhD.
Vedúci pracoviska: doc. Ing. Ján Lang, PhD.
Konzultant: doc. Ing. Ján Lang, PhD.

Názov práce: **Inteligentný asistent tréningu prezentačných schopností**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

Z prezentovania pred publikom alebo na verejnosti mávajú hlavne menej skúsení rečníci rôzne obavy, napríklad či bude ich prezentácia dostatočne zaujímavá, zrozumiteľná, plynulá a bez chýb. Tieto obavy sú prirodzené, hlavne pokiaľ nemáme dostatok skúseností, či nie sme zvyknutí verejne vystupovať. Tieto obavy je možné zvládnuť vhodným tréningom. Oboznámte sa s problematikou úspešného a efektívneho prezentovania a preskúmajte moderné prístupy tréningu prezentačných schopností. Analyzujte najčastejšie problémy, s ktorými sa stretávajú rečníci počas prezentovania, ako sú napríklad nesprávne využívanie neverbálnych a verbálnych prejavov. Identifikujte, ktoré nevhodné javy najviac ovplyvňujú kvalitu prezentácie a zapracujte ich do finálneho riešenia. Navrhnite inteligentného asistenta na tréning prezentačných schopností, ktorý bude použitý pri nácviku verejných prezentácií a bude poskytovať spätnú väzbu na neverbálne a verbálne prejavy rečníka. Využite metódy spracovania obrazu a zvuku na detekciu nevhodných javov počas prezentácie. Na základe zistených javov navrhnite a implementujte systém odporúčaní, ktorý rečníkovi poskytuje spätnú väzbu a usmernenia na zlepšenie jeho prezentačných schopností. Navrhnuté riešenie implementujte a overte.

Termín odovzdania diplomovej práce: 04. 05. 2026
Dátum schválenia zadania diplomovej práce: 27. 04. 2026
Zadanie diplomovej práce schválil: prof. Ing. Vanda Benešová, PhD. – garantka študijného programu

Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Bratislave, Máj 2026

Bc. Matej Kandráč

Anotácia

Slovenská technická univerzita v Bratislave

FAKULTA INFORMATIKY A INFORMAČNÝCH TECHNOLOGIÍ

Študijný program: Inteligentné softvérové systémy

Autor: Bc. Matej Kandráč

Diplomová práca: Inteligentný asistent tréovania prezentačných
schopností

Vedúci diplomovej práce: Ing. Bahleda Miroslav, PhD.

Máj 2026

V tejto diplomovej práci som sa najprv zamerlal na celú problematiku prezentovania, kde som sa napokon bližšie sústredil na verejné prezentácie. Najprv som sa venoval významu prezentácie ako takej a jej rozdeleniu. Následne som definoval pojem prezentačných schopností a rozdelil komunikáciu na verbálnu a neverbálnu časť. Práca taktiež obsahuje analýzu neverbálnej komunikácie a kladie dôraz na najpodstatnejšie negatívne javy. V práci je zahrnutá aj analýza vlastností hlasu a verbálnej komunikácie. V rámci analýzy je preskúmaná aj problematika časových radov, s dôrazom na segmentáciu a detekciu trendu. Pri porovnaní existujúcich riešení som sa sústredil na štyri nájdené existujúce riešenia a porovnal som ich. Po analýze som navrhol komplexné riešenie, ktoré využíva mikroslužbovú architektúru pre dosiahnutie flexibilitnosti a rozšíriteľnosti riešenia. Pri analýze nevhodných javov som využíval počítačové videnie a rôzne techniky spracovania zvuku. Pre používateľov som taktiež navrhol mobilnú aplikáciu pre nahrávanie videí a zobrazenie vizualizácií. Súčasťou práce je aj používateľská štúdia, ktorá overila vplyv jednotlivých dimenzií prezentácie na jej celkové vnímanie a vplyv časovej distribúcie negatívnych javov. Výsledky štúdie boli priamo zapracované do hodnotiaceho

modelu systému, čím sa výrazne zvýšila jeho zhoda s ľudskými hodnoteniami.
Navrhnuté riešenie som napokon úspešne implementoval a otestoval.

Annotation

Slovak University of Technology Bratislava

FACULTY OF INFORMATICS AND INFORMATION TECHNOLOGIES

Degree course: Intelligent software systems

Author: Bc. Matej Kandráč

Diploma's thesis: Intelligent assistant for training presentation skills

Supervisor: Ing. Bahleda Miroslav, PhD.

May 2026

In this diploma thesis, I first focused on the overall issue of presenting, eventually narrowing my attention to public presentations. I began by addressing the significance of presentations as such and their classification. I then defined the concept of presentation skills and divided communication into verbal and non-verbal components. The thesis also includes an analysis of non-verbal communication and emphasizes the most significant negative phenomena. It further contains an analysis of voice characteristics and verbal communication. As part of the analysis, the topic of time series is also examined, with a focus on segmentation and trend detection. When comparing existing solutions, I focused on four found approaches and compared them. After the analysis, I proposed a comprehensive solution that uses a microservices architecture to achieve flexibility and scalability. I also designed a mobile application for users to record videos and display visualizations. The thesis also includes a user study that verified the influence of individual presentation dimensions on overall perception and the impact of temporal distribution of negative phenomena. The study's findings were directly incorporated into the system's scoring model, significantly improving its agreement with human ratings. Finally, I successfully implemented and tested the proposed solution.

Obsah

1	Úvod	1
2	Analýza problematiky	3
2.1	Význam prezentácie	3
2.2	Prezentačné schopnosti	4
2.3	Stavba komunikácie	5
2.3.1	Neverbálna komunikácia	6
2.3.2	Vlastnosti hlasu	8
2.3.3	Verbálna komunikácia	9
2.4	Časové rady	10
2.4.1	Segmentácia časových radov	10
2.4.2	Detekcia trendu	11
2.5	Spracovanie audio signálov	11
2.5.1	Základy digitálneho audio signálu	12
2.5.2	Vzorkovacia rýchlosť	12
2.5.3	Bitová hĺbka	13
2.5.4	Extrakcia audio vlastností	13
2.6	Existujúce riešenia	14
2.6.1	MACH	14

2.6.2	ROC Speak	15
2.6.3	GestureLens	15
2.6.4	RAP	16
2.6.5	Porovnanie riešení	17
2.7	Definícia problému	19
2.7.1	Chýbajúce overenie vplyvu dimenzií na celkový dojem . . .	19
2.7.2	Neznámy vplyv distribúcie negatívnych javov v čase	19
2.7.3	Fragmentácia pokrytia detekovaných dimenzií	20
2.7.4	Potreba vlastnej extrakcie dát	20
2.7.5	Chýbajúca časová analýza	20
2.7.6	Formulácia problému	21
3	Návrh riešenia	25
3.1	Špecifikácia požiadaviek	26
3.2	Prípady použitia	27
3.2.1	Natočenie videa prezentácie	28
3.2.2	Celková analýza prezentácie	29
3.3	Použité technológie	29
3.3.1	Mobilná aplikácia	29
3.3.2	Serverová časť - mikroslužby	30
3.3.3	API Gateway	30
3.3.4	Počítačové videnie - MediaPipe	30
3.3.5	Spracovanie zvuku	31
3.3.6	Analýza časových radov	31
3.3.7	Databáza	32
3.3.8	Kontajnerizácia	32
3.4	Architektúra riešenia	32
3.4.1	Komponenty systému	32

3.4.2	Mapovanie požiadaviek na komponenty	35
3.4.3	Komponentový diagram	36
4	Implementácia riešenia	41
4.1	Spracovanie videa	42
4.1.1	Použité kľúčové body	42
4.1.2	Nastaviteľné parametre	43
4.1.3	Postup extrakcie	44
4.2	Spracovanie zvuku	45
4.2.1	Vzorkovacia rýchlosť	45
4.2.2	Redukcia šumu	46
4.2.3	Bitová hĺbka	46
4.3	Transkripcia reči	46
4.3.1	Whisper model	47
4.4	Detekcia monotónnosti	47
4.5	Analýza hlasitosti	49
4.6	Detekcia výplňových slov	51
4.6.1	Detekcia slovných výplňových slov	51
4.6.2	Detekcia neverbálnych zvukov (uhh)	52
4.6.3	Identifikácia úsekov so zvýšenou hustotou výplňových slov	54
4.7	Detekcia očného kontaktu	55
4.7.1	Výpočet uhlov hlavy	56
4.7.2	Definícia zóny publika	58
4.7.3	Detekcia otočenia chrbtom	58
4.8	Detekcia pohybov rúk	59
4.8.1	Normalizácia kľúčových bodov	59
4.8.2	Výpočet rýchlosti zápästí	59
4.8.3	Detekcia nedostatočnej gestikulácie	59

4.9	Detekcia pohybu bokov (tancovanie)	60
4.9.1	Detekcia kývavého pohybu	61
4.10	Segmentácia časových radov	62
4.10.1	Algoritmus PELT	62
4.10.2	Parameter citlivosti	62
4.10.3	Výstup segmentácie	63
4.11	Hodnotenie prezentácie	63
4.11.1	Štruktúra hodnotenia	63
4.11.2	Výpočet dimenzionálnych skóre	64
4.11.3	Odporúčania	65
4.12	Mobilná aplikácia	66
4.12.1	Nahrávanie prezentácie	66
4.12.2	Výsledky analýzy	67
5	Výskumná štúdia	71
5.1	Výskumné otázky a hypotézy	71
5.2	Dizajn experimentu	72
5.2.1	Príprava videí	72
5.2.2	Zber dát	73
5.3	Štatistické metódy	74
5.4	Výsledky	75
5.4.1	H1.1 — Vplyv dimenzií na celkové hodnotenie	76
5.4.2	H1.2 — Monotónnosť vs. výplňové slová	78
5.4.3	H2.1 — Distribúcia výplňových slov	78
5.4.4	Repeated Measures ANOVA	79
5.5	Implikácie pre systém	79
5.5.1	Porovnanie modelov	80
5.6	Validácia hodnotiaceho modelu	81

5.6.1	H3.1 — Výskumom odvodené váhy zvyšujú zhodu modelu s ľudským hodnotením	81
5.6.2	H3.2 — Distribučná penalizácia presnejšie kopíruje ľudský rozdiel V5 vs. V6	82
5.6.3	Obmedzenia štúdie	83
6	Hodnotenie systému	85
6.1	Validácia detektorov	85
6.1.1	Metodika merania	85
6.1.2	Testovací materiál	86
6.1.3	Výsledky	87
6.1.4	Analýza chýb	87
6.2	Pilotná štúdia účinnosti	89
6.2.1	Výsledky — objektívne metriky	90
6.2.2	Výsledky — subjektívne hodnotenie	91
6.2.3	Záver štúdie	92
7	Záver	95
7.1	Zhrnutie dosiahnutých výsledkov	95
7.2	Výsledky výskumnej štúdie	96
7.3	Obmedzenia systému	97
7.4	Možnosti ďalšieho rozvoja	97
7.5	Záverečné zhodnotenie	98
A	Technická dokumentácia	A-1
A.1	Architektúra a mikroslužby	A-1
A.2	Databázová schéma	A-2
A.2.1	Tabuľka <code>recording</code>	A-2
A.2.2	Tabuľka <code>frame_data</code>	A-3

A.2.3	Tabuľka landmark	A-3
A.2.4	Tabuľka word	A-4
A.3	API rozhrania	A-4
A.3.1	API gateway (port 8000)	A-5
A.3.2	Priame endpointy mikroslužieb	A-6
A.4	Štruktúra projektu a verzie knižníc	A-6
A.4.1	Štruktúra projektu	A-6
A.4.2	Konfigurácia prostredia	A-8
A.5	Inštalácia a nasadenie	A-9
A.5.1	Predpoklady	A-9
A.5.2	Konfigurácia prostredia	A-10
A.5.3	Spustenie serverovej časti	A-10
A.5.4	Spustenie mobilnej aplikácie	A-11
B	Plán práce	B-1
B.1	Letný semester DP1	B-1
B.2	Zimný semester DP2	B-1
B.3	Letný semester DP3	B-2
C	Obsah digitálnej časti práce	C-1

Úvod

Každý z nás počas svojho života aspoň raz prezentoval, či to bola prezentácia jednoduchého školského projektu, pracovný pohovor, obhajoba práce alebo profesionálne vystúpenie pred publikom. Výsledok prezentácie má často významný dopad na našu budúcnosť, alebo na zmýšľanie publika. Schopnosť jasne, presvedčivo a sebavedome komunikovať myšlienky je čoraz dôležitejšia nielen pre manažérov či učiteľov, ale aj pre študentov, výskumníkov či pracovníkov v kreatívnych odvetviach.

Mnohí ľudia však pociťujú pri prezentovaní stres, neistotu alebo nedostatok skúseností, čo im bráni v tom, aby naplno využili svoj potenciál. Tradičné formy nácviku, ako sú školenia, kurzy alebo osobné konzultácie, môžu byť časovo náročné, drahé alebo ťažko dostupné. V tomto kontexte vzniká potreba modernejších a flexibilnejších riešení, ktoré by dokázali poskytnúť individuálnu spätnú väzbu a pomohli používateľom zlepšovať sa.

Jedným z takýchto riešení môže byť inteligentný tréner prezentačných schopností, ktorý by využíval moderné technológie, ako sú umelá inteligencia, analýza reči a analýza obrazu na podporu rozvoja komunikačných zručností. Cieľom tejto práce je priblížiť túto tému a ukázať možnosti, ako môže technológia prispieť k efektívnejšiemu a dostupnejšiemu trénovaniu prezentačných schopností.

Analýza problematiky

V kontexte prezentácií existuje mnoho foriem prezentovania, ako napríklad pracovné pohovory, verejné vystúpenia alebo aj školské prezentácie. Nakoľko zachytiť všetky tieto formy v rámci jedného riešenia je náročné, rozhodol som sa sústrediť iba na verejné prezentácie pred publikom.

Pred samotným návrhom riešenia je potrebné pochopiť základné pojmy spojené s prezentáciami a prezentačnými schopnosťami. V nasledujúcich podkapitolách postupne vysvetlím mnou analyzované pojmy úzko spojené s touto problematikou.

2.1 Význam prezentácie


Cieľom prezentácie je často podať informácie poslucháčom alebo publiku za určitým účelom. Tieto účely sú rôzne a každý zdroj uvádza iné množstvo [30]. Základné účely sú:

- Informovať
- Presvedčiť
- Inšpirovať
- Pobaviť

Pre určenie účelu prezentácie je potrebné si uvedomiť, čo chcem prezentáciou dosiahnuť. Príkladom je, že idem predniesť nový návrh na reklamnú kampaň pre

potenciálneho investora. V tomto prípade chcem presvedčiť moje publikum (investorov), že môj nápad je najlepší. Povedzme, že chceme znova odprezentovať nový návrh na reklamnú kampaň začínateľom v oblasti podnikania. Účel tejto prezentácie by bol inšpiratívny.

Podľa tohto účelu prezentácie vie prezentujúci, na aké informácie alebo formu prejavu sa má najviac sústrediť. Napríklad pri informatívnej prezentácii musí prezentujúci využívať prevažne najpodstatnejšie informácie, pri presvedčaní silné fakty, pri inšpirovaní príbehy alebo iné citové prejavy a pre pobavenie vtipné výroky alebo príbehy[30].



Obr. 2.1: Účely prezentácie

2.2 Prezentačné schopnosti

V mojej práci je najpodstatnejšie pochopiť, čo sú to **prezentačné schopnosti** a čo všetko tento pojem zahŕňa. Prezentačné schopnosti sú vlastnosti a kvality potrebné pre vytváranie a prednášanie presvedčivých prezentácií, ktoré efektívne predávajú informácie a nápady[29]. Zahŕňajú nie len hovorené slová ale aj reč tela, vizuálne pomôcky a všeobecnú charizmu prezentujúceho[29]. Pod vizuálnymi pomôckami si môžeme predstaviť priamo obrazovú prezentáciu, ktorú prezentujúci prednáša.

V mojej práci sa nechcem venovať analýze vizuálnych pomôcok prezentácie, ale sústrediť sa skôr na **verbálne** a **neverbálne** aspekty prezentačných schopností, čím docielim zlepšenie samotnej prezentácie. Vizuálne pomôcky sú podstatné pre prezentáciu, no ja sa chcem zamerať na prezentačné schopnosti.

2.3 Stavba komunikácie

Počas mojej analýzy riešenia som narazil na známe pravidlo 7-38-55, ktoré často býva spájané s medziľudskou komunikáciou. Podľa tohto pravidla iba 7 % významu v komunikácii sprostredkujú samotné slová, zatiaľ čo 38 % pripadá na tón hlasu a až 55 % na reč tela[22]. Nakoľko tón hlasu spadá pod neverbálnu komunikáciu, toto pravidlo teda hovorí, že 93% komunikácie tvorí neverbálna komunikácia.

Hoci je toto pravidlo často citované, v odborných kruhoch býva zároveň aj kritizované. Bolo odvodené z výskumu psychológa Alberta Mehrabiana, ktorý však skúmal veľmi špecifické situácie, predovšetkým rozpory medzi verbálnym a neverbálnym prejavom pri vyjadrovaní emócií. Preto ho nemožno aplikovať univerzálne na všetky formy komunikácie[17].

Napriek tomu poukazuje na dôležitý fakt, a to že neverbálna zložka komunikácie (napríklad mimika či gestá) má v medziľudskom dorozumievaní výrazný vplyv a neraz môže byť rovnako dôležitá ako samotné slová.

Zároveň sa dá využiť logické členenie z tohto pravidla, konkrétne, že vieme rozdeliť komunikáciu do troch kategórií:


- Verbálne
- Paralingvistické (hlasové)
- Neverbálne

Keďže však toto pravidlo neodráža skutočný podiel jednotlivých aspektov na vnímaní prezentačných schopností, je potrebné skúmať, ktoré z týchto javov sú publikom reálne vnímané a aký majú vplyv na celkové hodnotenie prezentácie.

2.3.1 Neverbálna komunikácia

Pod neverbálnou komunikáciou si môžeme predstaviť mnoho vecí. Či už náš postoj, spôsob ako chodíme, výraz tváre, kde máme ruky, no zároveň aj ako rozprávame. V kontexte verejných prezentácií je podstatné nájsť práve také javy neverbálnej komunikácie, ktoré najviac nepriaznivo pôsobia na kvalitu prezentácie. Zároveň pri neverbálnej komunikácii je častý problém **sebareflexie**, pretože tieto prejavy sú často podvedomé, a tým pádom prezentujúci potrebuje dostať spätnú väzbu[25].

Nakoľko negatívne pôsobiacich neverbálnych aspektov je príliš veľa, je potrebné vybrať tie najdôležitejšie. Jeden zo zdrojov vykonal rozhovor s desiatimi expertami v oblasti verejného rozprávania, čo je forma prezentácie, na ktorú som sa rozhodol zamerať[28]. Po rozhovoroch s odborníkmi zostavili tabuľku s údajmi, ktoré rozdelili do viacerých podkategórií.



Obr. 2.2: Rozdelenie aspektov neverbálnej komunikácie

Z vyhotovenej tabuľky som vybral tie javy, ktoré najčastejšie spomenuli odborníci a zaradili ich medzi negatívne javy.

Názov javu	Aspekt
Otočený chrbtom k publiku	Postoj
Tancovanie (tango a merengue)	Postoj
Ruky vo vreckách alebo za chrbtom	Postoj
Žiadna gestikulácia	Gestikulácia
Držanie / hranie sa s predmetmi	Gestikulácia
Ruky nad hlavou	Gestikulácia
Prázdny výraz tváre	Výraz tváre
Žiaden očný kontakt	Očný kontakt
Státie za počítačom	Využitie javiska
Konštantný pohyb po javisku	Využitie javiska
Rozprávanie hlasno pre seba	Hlas

Tabuľka 2.1: Tabuľka negatívnych javov neverbálnej komunikácie

Gestikulácia plní v prezentácii niekoľko dôležitých funkcií — vizuálne zdôrazňuje hovorené slovo, pomáha prezentujúcemu štruktúrovať myšlienky a udržuje pozornosť publika[28]. Jej absencia býva publikom vnímaná ako prejav nezáujmu alebo

nervozity, zatiaľ čo nadmerná a nekontrolovaná gestikulácia pôsobí rušivo a odvádza pozornosť od obsahu prezentácie[28].

Jeden z najpodstatnejších aspektov pri verejnom prezentovaní je očný kontakt. Udržiavanie očného kontaktu pomáha pri vytváraní spojenia medzi poslucháčmi, zlepšuje koncentráciu a preukazuje autoritu a sebavedomie[27].

Jeden zo zdrojov uvádza, že pri prezentovaní je potrebné využívať signál k zvuku (signal-to-noise). Signál tu definujeme ako akékoľvek pohyby, ktoré dodávajú vášmu rozprávaniu podstatu a ďalej zapájajú publikum, ako napríklad odovzdanie správy rukami alebo očný kontakt s publikom. [35] Tento pojem znamená, že by prezentujúci mal využívať pohyby spolu s hovoreným slovom. V prípade prepoužívania signálov môže pôsobiť hovorené slovo neprirodzené alebo môžu signály pôsobiť príliš rušivo.

2.3.2 Vlastnosti hlasu

Pri využívaní svojho hlasu je potrebné dávať si pozor hneď na niekoľko jeho vlastností. Túto problematiku opisoval v rámci svojej prednášky Julian Treasure[34] a poukázal na tieto hlasové vlastnosti:

- hlasový register
- farba hlasu
- prozódia
- tempo
- výška hlasu
- hlasitosť

Avšak nakoľko detekcia všetkých týchto vlastností hlasu je pomerne komplikovaná,

je potrebné z nich vybrať tie najpodstatnejšie. V predošlej sekcii zameranej na neverbálnu komunikáciu odborníci spomenuli niektoré z hore napísaných vlastností hlasu a zároveň aj ako ich negatívne prezentujúci využil. Konkrétne ide o problémy monotónnosti, rýchleho rozprávania a tichého rozprávania.

Osobitú pozornosť si zaslúži pojem **monotónnosti hlasu**. Monotónny prejav je charakterizovaný konštantnou výškou tónu a rytmom bez výraznejšej variácie v priebehu celej prezentácie. Takýto hlas stráca schopnosť zdôrazňovať kľúčové myšlienky a pôsobí na publikum nudne, čo znižuje mieru vnímania a zapamätania prezentovaného obsahu[40]. Pre účely tejto práce definujem monotónnosť hlasu ako nízku štandardnú odchýlku alebo rozsah základnej frekvencie hlasu v časovom úseku počas prezentácie.

2.3.3 Verbálna komunikácia

Z hľadiska verbálnej komunikácie sa pri prezentáciách môžeme zamerať na mnoho problémov. S problémami verbálnej komunikácie je často spôsobená prerušením plynulosti reči, ktorá môže mať viac foriem. Namiesto prednášania správne štruktúrovanej reči prezentujúci často hovoria zneistene, opakujú sa a opravujú svoje hovorené slovo.[16] Častým javom je aj takzvané používanie výplňových slov alebo výplňových zvukov. Niekoľko štúdií preukázalo, že nadmerné používanie výplňových slov alebo zvukov negatívne ovplyvňuje prezentačnú zručnosť prezentujúceho.[18] [10] Preto som sa v mojej práci rozhodol venovať sa práve identifikácii týchto slov. V jednom zo zdrojov bolo uvedené, že minimálna prijateľná miera výplňových slov je 1,26 na 100 slov a po jeho prekročení začne klesať kredibilita prezentujúceho u poslucháčov. [10]

2.4 Časové rady

Pre pochopenie mojej práce je podstatné pochopiť aj čo sú to časové rady. Časové rady sú jednoducho sekvencie dátových bodov merané v diskrétnych časových bodoch, ktoré sú zoradené chronologicky podľa času[13]. V mojej práci sa budem zaoberať presne takýmito dátami, nakoľko budem musieť analyzovať jednotlivé vlastnosti hlasu a pohyby používateľa v jednotlivých časových bodoch počas celej prezentácie. Problematika časových radov je pomerne rozsiahla, no po uvažovaní, ktoré vlastnosti a algoritmy časových radov sa budem sústrediť som sa rozhodol zamerať na dve, a to konkrétne na **segmentáciu** a **detekciu trendu**.

2.4.1 Segmentácia časových radov

Segmentácia je rozdeľovanie časových radov na časti, segmenty, ktoré logicky rozdelia dáta[39]. Z hľadiska segmentácie je potrebné nájsť také body v časovom rade, ktoré rozdelia dáta podľa odchýlky, priemeru alebo pri zmene trendu. Existuje mnoho algoritmov, ktoré zabezpečujú segmentáciu časových radov. Často sa delia na dve kategórie, a to **offline** a **online**[39]. Offline reprezentuje algoritmy, ktoré majú všetky dáta dostupné naraz a online tie, ktoré dáta dostávajú postupne. Ďalšie rozdelenie je podľa spôsobu detekcie bodov zmien, a to sú:

- Top-down approach
- Bottom-up approach
- Sliding window
- SWAB (sliding window and bottom-up)

Pre konkrétnu implementáciu segmentácie bol zvolený algoritmus **PELT** (Pruned Exact Linear Time)[15]. PELT patrí do kategórie offline algoritmov a hľadá body

zmien minimalizovaním penalizovanej cenovej funkcie.

Z hľadiska využitia v rámci mojej práce sa môže segmentácia použiť pre rozdelenie dát na úseky, kde ostáva rovnaký trend alebo sa výrazne zmení priemer. Napríklad pri analýze pohybov rúk môže algoritmus rozoznať, že prezentujúci využíva pohyby rúk výrazne v prvej časti prezentácie (trend stúpa alebo je konštantný) a následne ich prestane kvôli tréme využívať (trend klesá). Zároveň body zmien často indikujú anomálie, napríklad prudký pohyb rukami alebo náhle zvýšenie hlasitosti. Tieto údaje môžu byť pre prezentujúceho podstatné, aby si tieto často podvedomé javy uvedomil a zlepšil sa.

2.4.2 Detekcia trendu

Trend je vzor v časovom rade, ktorý sa vyznačuje konzistentným správaním údajov (napríklad stúpajúcim alebo klesajúcim pohybom) v priebehu času[2]. V niektorých oblastiach sa trend definuje aj ako všeobecný smer priemeru v dátach[23].

Využitie detekcie trendu v rámci mojej práce chcem využiť pri analýze jednotlivých segmentov prezentácie. Napríklad zistím, či v prvom segmente prezentácie prezentujúci prestal postupne využívať gestikuláciu. V kontexte tejto práce je trend v jednotlivých segmentoch odvodený zo štatistických charakteristík — priemeru a štandardnej odchýlky — ktoré algoritmus PELT priradí každému detegovanému segmentu. Porovnaním týchto hodnôt naprieč segmentmi je možné identifikovať, či sledovaná dimenzia počas prezentácie stúpa, klesá alebo ostáva stabilná.

2.5 Spracovanie audio signálov

Nakoľko moje riešenie zahŕňa analýzu hlasu a verbálnych aspektov prezentácie, je nevyhnutné pochopiť základné princípy spracovania audio signálov. V tejto sekcii

sa zameriam na teoretické základy digitálneho zvuku a metódy jeho spracovania, ktoré sú kľúčové pre implementáciu detekcie vlastností hlasu.

2.5.1 Základy digitálneho audio signálu

Zvuk je vo svojej podstate vlnenie, ktoré sa šíri vzduchom. V analógovej forme je zvuk reprezentovaný ako kontinuálny signál. Na to aby sme vedeli spracovávať zvukové signály musíme analógový signál dostať do digitálnej formy prostredníctvom procesu nazývaného **vzorkovanie** (sampling)[6].

Digitálny audio signál je teda diskretná reprezentácia analógového zvukového signálu, kde v pravidelných časových intervaloch meráme amplitúdu (veľkosť) signálu. Výsledkom je časový rad dát, ktoré približne opisujú pôvodný spojitý signál[6]. Kvalita tohto odhadu závisí od dvoch základných parametrov: **vzorkovacej rýchlosti** a **bitovej hĺbky**. Ak chcem v mojej práci spracovávať zvuk, budem potrebovať signál pripraviť tak, aby bol v čo najlepšej kvalite s ohľadom na ich veľkosť.

2.5.2 Vzorkovacia rýchlosť

Vzorkovacia rýchlosť (sample rate) definuje počet vzoriek (samples) odobratých za sekundu a vyjadruje sa v jednotkách Hertz (Hz). Napríklad vzorkovacia rýchlosť 16 000 Hz znamená, že za jednu sekundu je z analógového signálu odobratých 16 000 diskretných vzoriek. Štandardne je vzorkovacia rýchlosť medzi 8kHz a 48kHz.[20]

Výber vzorkovacej rýchlosti priamo ovplyvňuje frekvenčné pásmo, ktoré dokáže digitálny signál zachytiť. Podľa **Nyquistovho-Shannonovho teorému** musí byť vzorkovacia rýchlosť aspoň dvojnásobkom najvyššej frekvencie, ktorú chceme v signáli zachytiť, inak môže nastať aliasing, ktorý spôsobí, že sa dáta skreslia a

nesprávne sa interpretujú.[1]

Pre analýzu reči sa najčastejšie používa vzorkovacia rýchlosť 16 kHz, pretože ľudský hlas sa väčšinou nachádza vo frekvenčnom pásme do 8 kHz a táto vzorkovacia rýchlosť podľa Nyquistovho teorému postačuje na jeho zachytenie. [20]

2.5.3 Bitová hĺbka

Bitová hĺbka (bit depth) určuje, koľko bitov sa používa na reprezentáciu amplitúdy každej jednotlivkej vzorky. Čím vyššia je bitová hĺbka, tým presnejšie dokážeme zachytiť dynamický rozsah signálu[31].

Dynamický rozsah v decibeloch (dB) možno aproximovať vzťahom:

$$DR \approx 6.02 \cdot n \quad (2.1)$$

Kde n predstavuje počet bitov. Napríklad 16-bitové audio má dynamický rozsah približne 96 dB, čo je dostatočné pre väčšinu aplikácií spracovania reči. Túto bitovú hĺbku má aj väčšina mobilných telefónov.

2.5.4 Extrakcia audio vlastností

Pre analýzu charakteristík hlasu je potrebné z audio signálu extrahovať relevantné vlastnosti (features). V kontexte analýzy prezentačných schopností sú najpodstatnejšie tieto vlastnosti:

Výška hlasu reprezentuje základnú frekvenciu hlasiviek a je kľúčová pre detekciu monotónnosti. Pre extrakciu pitch existuje niekoľko algoritmov, ako napríklad YIN, PYIN alebo autokorelačné metódy.[5] Hodnoty pitch pre mužský hlas sa typicky pohybujú v rozsahu 85-180 Hz, pre ženský hlas 165-255 Hz[19].

Hlasitosť sa najčastejšie meria pomocou RMS (Root Mean Square) energie signálu v krátkych časových oknách. [24]

Tieto extrahované vlastnosti môžu byť následne analyzované ako časové rady, kde môžeme aplikovať metódy segmentácie a detekcie trendov opísané v predchádzajúcich sekciách.

2.6 Existujúce riešenia

V rámci mojej analýzy som sa taktiež rozhodol preskúmať už existujúce riešenia, ktoré sa tejto problematike venovali. Narazil som na niekoľko riešení, no rozhodol som sa vybrať iba niekoľko.

2.6.1 MACH

Mach, alebo My automated conversation coach, je systém, ktorý používa virtuálneho asistenta, ktorý číta výrazy tváre, hlas a prozódium a ponúka spätnú väzbu v reálnom čase[14]. Toto riešenie kladie dôraz na použitie virtuálneho asistenta, ktorý má pripomínať skutočného trénera, ktorý sa snaží prirodzene reagovať a dávať spätnú väzbu. Po skončení tréningu tento asistent zozbieral a zobrazil niekoľko údajov, a to konkrétne:

- Celková dĺžka páuz
- Tempo reči (počet slabík za minútu)
- Slabý jazyk (Výplňové slová, percentuálne vyjadrené pre celkovo hovorené slová)
- Variácia výšky hlasu
- Úsmev

- Kývanie hlavou
- Hovorené slová
- Hlasitosť

2.6.2 ROC Speak

ROC Speak je online platforma poskytujúca spätnú väzbu na úsmev, pohyby tela, moduláciu hlasu a používanie výplňových slov[42]. Toto riešenie rozdelilo spätnú väzbu do dvoch komponentov, a to na **automatizovanú** a **subjektívnu** spätnú väzbu.

Automatizovaná spätná väzba zachytávala niekoľko údajov:

- Úsmev
- Pohyby tela
- Hlasitosť a výška hlasu
- Transkript a prozódia slov
- Slabé slová

Subjektívna spätná väzba bola vykonávaná formou komentárov a hodnotenia od iných ľudí. Systém dokonca automaticky ohodnocoval, či je daný komentár negatívny alebo pozitívny a následne zobrazoval najrelevantnejšie komentáre používateľovi.

2.6.3 GestureLens

GestureLens je systém vizuálnej analýzy, ktorý uľahčuje preskúmanie používania gest vo videách z prezentácií, a to na základe gest aj obsahu[41]. Snaží sa nájsť

podobnosti gést, ktoré spája s hovoreným slovom a využíva dynamic time warping pre zisťovanie podobností gest.

Toto riešenie dokáže detekovať a analyzovať:

- Pohyby rúk
- Korelácie hovoreného slova s gestami
- Transkripcia hovoreného slova
- Priesorové využitie gest (heatmapa)

Tento systém je pomerne komplikovaný a detailne analyzuje primárne pohyby rúk.

2.6.4 RAP

RAP (Retroalimentación Automática de Presentaciones) je systém vyvinutý na univerzite ESPOL v Ekvádore[9]. Systém automaticky vyhodnocuje nahrávky verejných prezentácií a poskytuje spätnú väzbu na neverbálne aj verbálne aspekty reči. Do roku 2024 spracoval viac ako 3 726 nahrávok od 2 191 používateľov.

Systém analyzuje:

- **Postoj** — pomocou BlazePose (MediaPipe) extrahuje kľúčové body tela a klasifikuje ich do piatich posturálnych kategórií (ruky otvorené, ruky dole, ruky v bok atď.) pomocou natrénovanej doprednej neurónovej siete
- **Smer pohľadu** — klasifikuje pohľad do štyroch smerov (do publika, dozadu, doľava, doprava) pomocou algoritmu k-najbližších susedov (kNN)
- **Výplňové slová** — detekuje akustické charakteristiky výplňových zvukov priamo z audio signálu pomocou nástroja Praat (analýza formantov), bez

transkripcie reči

- **Hlasitosť** — meria úroveň hlasitosti reči voči kalibrovanej úrovni ticha v miestnosti

Výstupom je bodové skóre pre každú dimenziu a heatmapa zobrazujúca frekvenciu jednotlivých póz a pohľadov v čase prezentácie.

2.6.5 Porovnanie riešení

Po analýze týchto štyroch existujúcich riešení som sa rozhodol vytvoriť tabuľku parametrov, ktorá zachytáva podstatné parametre jednotlivých riešení, ako aj to, či detekujú negatívne javy, ktoré som opísal ako najpodstatnejšie v časti neverbálnej a verbálnej komunikácii.

	MACH	ROC Speak	GestureLens	RAP
Platforma	Desktop	Web	Web	Web
Otočenie chrbtom k publiku	Nie	Nie	Nie	Áno
Tancovanie	Nie	Nie	Nie	Nie
Ruky vo vrec-kách	Nie	Nie	Nie	Nie
Žiadna gesti-kulácia	Áno	Áno	Áno	Áno
Držanie / hranie sa s predmetmi	Nie	Nie	Nie	Nie
Ruky nad hlavou	Nie	Nie	Áno	Nie
Nedostatočná mimika	Áno	Áno	Nie	Nie
Očný kontakt	Áno	Nie	Nie	Áno
Státie za po-čítačom	Nie	Nie	Nie	Nie
Konštantný pohyb po javisku	Áno	Áno	Áno	Nie
Rozprávanie hlasno pre seba	Nie	Nie	Nie	Nie
Výplňové slová	Áno	Áno	Nie	Áno
Monotónnosť	Áno	Áno	Nie	Nie
Vysoké tempo reči	Áno	Áno	Nie	Nie
Nedostatočná hlasitosť	Áno	Áno	Nie	Áno
Hlavné zame-ranie	Mimika, očný kontakt, gestikulácia, tempo reči a výplňové slová	Intenzita úsmevu, po-hyby tela a verbálne aspekty	Korelácia hovoreného slova s gesti-kuláciou	Postoj, smer pohľadu, vý-plňové zvuky a hlasitosť

Tabuľka 2.2: Tabuľka porovnania atribútov riešení

Z tejto tabuľky môžeme vidieť, že žiadne z riešení nesleduje problémy spojené s kývaním bokov prezentujúceho, ani detailnú kinematickú analýzu pohybov rúk. RAP ako jediné riešenie detekuje otočenie chrbtom k publiku, avšak na rozdiel od ostatných neskúma monotónnosť hlasu ani tempo reči.

2.7 Definícia problému

Na základe analýzy existujúcich riešení a preštudovanej literatúry som identifikoval niekoľko kľúčových medzier — výskumných aj implementačných — ktoré poukazujú na potrebu komplexnejšieho prístupu k trénovaniu prezentačných schopností.

2.7.1 Chýbajúce overenie vplyvu dimenzií na celkový dojem

Žiadne z analyzovaných riešení nemá hodnotiaci model podložený výskumom. RAP napríklad využíva pevne nastavený bodový systém bez overenia, či zvolené váhy zodpovedajú skutočnému ľudskému vnímaniu. Rovnako ostatné riešenia (MACH, ROC Speak) poskytujú hodnotenia jednotlivých dimenzií izolovane, no neskúmajú, **aký relatívny vplyv má každá dimenzia na celkový dojem z prezentácie**. Nie je overené, či napríklad monotónnosť hlasu je pre publikum závažnejšia ako výplňové slová, alebo či vizuálne aspekty dominujú nad hlasovými. Táto medzera predstavuje prvý výskumný problém, ktorý je potrebné riešiť.

2.7.2 Neznámy vplyv distribúcie negatívnych javov v čase

Druhým výskumným problémom je, že žiadne z existujúcich riešení neskúma, či **časová distribúcia negatívnych javov** ovplyvňuje ich vnímanie. Konkrétne:

je rovnomerne rozložený výskyt výplňových slov vnímaný rovnako zle ako ten istý celkový počet sústredený v jednom bloku? Existujúce systémy hodnotia iba celkový výskyt javov, no ignorujú to, *kde* v prezentácii sa vyskytujú. Odpoveď na túto otázku má priamy dopad na to, ako by mal hodnotiaci model negatívne javy posudzovať.

2.7.3 Fragmentácia pokrytia detekovaných dimenzií

Z implementačného pohľadu som na základe analýzy identifikoval šesť dimenzií, ktoré sú z hľadiska prezentačných schopností kľúčové a zároveň automaticky detekovateľné: **gestikulácia, očný kontakt, pohyby bokov, výplňové slová, monotónnosť hlasu a hlasitosť**. Ako ukazuje tabuľka porovnania riešení (tabuľka 2.2), žiadne z existujúcich riešení nedetektuje všetkých šesť dimenzií súčasne. Pohyb bokov nie je detekovaný žiadnym z analyzovaných systémov, GestureLens úplne absentuje verbálnu analýzu a RAP neskúma monotónnosť. Táto fragmentácia poukazuje na potrebu vlastného komplexného riešenia.

2.7.4 Potreba vlastnej extrakcie dát

Existujúce riešenia fungujú ako uzavreté systémy (black-box) a neposkytujú prístup k surovým dátam získaným počas analýzy. Pre realizáciu vlastnej analýzy pohybov tela aj vlastností hlasu — vrátane metód segmentácie a detekcie trendov — je nevyhnutné vybudovať vlastný systém extrakcie a spracovania dát.

2.7.5 Chýbajúca časová analýza

Analyzované riešenia poskytujú prevažne **agregované štatistiky** (napríklad celkový počet výplňových slov, priemerná hlasitosť), no chýba im časová dimenzia analýzy. Prezentujúcemu nepovedia, v ktorom momente prezentácie prestali využí-

vať gestikuláciu alebo kedy sa zmenilo ich tempo reči. Identifikácia kritických bodov zmien prostredníctvom segmentácie a detekcie trendov môže poskytnúť oveľa hodnotnejšiu spätnú väzbu.

2.7.6 Formulácia problému

Problémom je absencia:

1. **Výskumu**, ktorý by overil, ktoré dimenzie prezentácie majú najväčší vplyv na celkové vnímanie jej kvality, a či distribúcia negatívnych javov v čase tento vplyv mení.
2. **Komplexného systému**, ktorý by detekoval všetkých šesť identifikovaných dimenzií (gestikulácia, očný kontakt, pohyby bokov, výplňové slová, monotónnosť, hlasitosť) v jednom riešení, poskytoval nielen agregované štatistiky, ale aj časovú analýzu, a mal hodnotiace váhy podložené výskumom.

Prečo je tento problém dôležitý? Prezentačné schopnosti sú kľúčové v mnohých oblastiach života, od akademického prostredia cez pracovné pohovory až po profesionálne vystúpenia. Tradičné formy nácviku (kurzy, tréningy) sú časovo aj finančne náročné a nie vždy dostupné. Moderný systém, ktorý poskytne komplexnú spätnú väzbu využitím pokročilých metód spracovania videa a zvuku a ktorého hodnotenie je podložené výskumom, môže zlepšiť prístup k trénovaniu prezentačných schopností a umožniť používateľom efektívne sa zlepšovať aj bez prítomnosti fyzického trénera.

Moje riešenie sa preto zameriava na dve vzájomne prepojené časti: realizáciu **výskumnej štúdie** ($n = 52$ respondentov), ktorá overuje vplyv jednotlivých dimenzií na celkové vnímanie prezentácie a skúma efekt časovej distribúcie negatívnych javov, a **implementáciu systému**, ktorého hodnotiace váhy sú výsledkami tejto


štúdie priamo podložené. Štúdia je podrobne popísaná v kapitole 5.

Návrh riešenia

Mojim návrhom je implementácia systému, ktorá umožní používateľovi prípravu pred prezentáciou a taktiež aj spracovanie už existujúceho záznamu prezentácie. Rozhodol som sa využiť **mobilné zariadenia**, ktoré dnes má takmer každý človek a sú vybavené vstavanou kamerou. Tieto zariadenia zároveň vedia vytvárať videa požadovanej kvality pre následné spracovanie. Z týchto zariadení vytvorí používateľ video, ktoré následne odošle pomocou mobilnej aplikácie na aplikačný server, ktorý prezentáciu zanalyzuje a poskytne spätnú väzbu. Moja aplikácia teda bude fungovať na **záznamoch** a nie na živom prenose. Aplikácia bude ponúkať tieto základné funkcie:

- Nahrávanie videa
- Spustenie analýzy
- Zobrazenie výsledkov a spätnej väzby

Jednoduchý proces používania teda vyzerá nasledovne:



Obr. 3.1: Základný proces používania aplikácie

3.1 Špecifikácia požiadaviek

Pred samotnou implementáciou som definoval niekoľko funkčných požiadaviek, ktoré by aplikácia mala spĺňať. Pri rozhodovaní, ktoré údaje budem detekovať, som sa odrážal od mojej analýzy a porovnania existujúcich riešení popísaného v kapitole analýzy problematiky.

- **Detekcia očného kontaktu:** Systém musí vedieť rozpoznať, či sa prezentujúci pozerá smerom do publika a nie je k nemu otočený chrbtom. Pre detekciu tohto javu sa využije viditeľnosť očí voči kamere, ktorá bude pred prezentujúcim.
- **Detekcia pohybu bokov:** Systém musí vedieť detekovať negatívny jav, nazývaný ako tancovanie (pohyb bokov zo strany na stranu). Detekcia bude počítaná akceleráciou stredu medzi bokmi, a bude detekovať kývanie z prava do ľava.
- **Detekcia pohybov rúk:** Systém musí vedieť detekovať nedostatočné pohyby rúk v prezentácii. Taktiež počítaná sledovaním akcelerácie rúk.
- **Detekcia monotónnosti:** Systém musí vedieť detekovať monotónny hlas. Monotónnosť hlasu je definovaná ako konštantný tón hlasu počas prezentácie. Bude sa teda sledovať zmena tónu hlasu.
- **Detekcia hlasitosti:** Systém musí vedieť detekovať nízku hlasitosť prezentujúceho.
- **Detekcia výplňových slov:** Systém musí vedieť detekovať výplňové slová.
- **Detekcia kritických bodov zmien:** Systém musí pre relevantné kritériá uvedené vyššie definovať kritické body, kedy sa drasticky zmenil doterajší priebeh. Ide napríklad o definovanie hranice, kedy prezentujúci prestal náhle

využívať všetky pohyby rúk, alebo že po prvej minúte prezentácie využíval veľké množstvo výplňových slov.


- **Generovanie výsledku:** Systém musí vedieť generovať dáta s hodnotením prezentácie, ako aj o odporúčaných zmenách pre jej zlepšenie.

3.2 Prípady použitia

Systém je navrhnutý pre podporu viacerých scenárov použitia. Na základe funkčných požiadaviek som identifikoval nasledujúce hlavné prípady použitia:

- **Nahratie videa prezentácie** - Používateľ nahrá video svojej prezentácie pomocou mobilnej aplikácie a odošle ho na server
- **Analýza prezentácie** - Systém vykoná komplexnú analýzu všetkých aspektov prezentácie
- **Zobrazenie výsledkov analýzy** - Používateľ si prezerá detailné výsledky analýzy s časovými stopami chýb a odporúčaniami
- **Správa nahrávok** - Používateľ môže prezeráť a spravovať svoje predchádzajúce nahrávky

V nasledujúcich podkapitolách popíšem dva najdôležitejšie prípady použitia. Pre grafické znázornenie som pripravil diagram prípadov použitia pre celý systém.



Obr. 3.2: Diagram prípadov použitia

3.2.1 Natočenie videa prezentácie

Používateľ otvorí aplikáciu a vyberie možnosť vytvorenia nového videa. Po udelení prístupu ku kamere systém zobrazí kalibračný náhľad s detekovanou pózou tela, čím si používateľ môže overiť správne umiestnenie pred kamerou ešte pred spustením nahrávania. Po stlačení tlačidla aplikácia odpočíta tri sekundy a začne zaznamenávať prezentáciu. Po ukončení nahrávania má používateľ možnosť video orezať, pomenovať a odoslať na server na spracovanie. Video je zároveň uložené lokálne v zariadení a dostupné v zozname nahrávok.

3.2.2 Celková analýza prezentácie

Po dokončení spracovania videa a zvuku na serveri môže používateľ spustiť celkovú analýzu prezentácie pri zobrazení videa v zozname nahrávok. Systém prostredníctvom orchestrátora paralelne spustí všetky analytické mikroslužby, výsledky agreguje a vygeneruje hodnotenie s odporúčaniami pre zlepšenie. V prípade výpadku niektorej mikroslužby pokračujú ostatné analýzy a chýbajúce výsledky sú označené ako nedostupné. Výsledky zahŕňajú všetky dostupné štatistiky, ako aj kritické body zmien a celkové skóre prezentácie.

3.3 Použité technológie

Riešenie je postavené na kombinácii moderných technológií pre mobilný vývoj, serverové spracovanie a analýzu údajov. Kľúčovým architektonickým rozhodnutím je, že **všetka analýza prebieha na serverovej strane**, čím sa minimalizujú výpočtové nároky na mobilné zariadenie a umožní sa budúce rozšírenie systému bez nutnosti aktualizácie mobilnej aplikácie.

3.3.1 Mobilná aplikácia

Pre mobilnú aplikáciu bol zvolený framework **Flutter**[12], ktorý umožňuje vývoj cross-platform aplikácií pre iOS a Android z jedného kódového základu. Flutter poskytuje natívnu výkonnosť a integruje sa s kamerou mobilného zariadenia pre nahrávanie videa. Mobilná aplikácia bude mať limitovanú úlohu — zabezpečí nahrávanie videa, jeho odoslanie na server a zobrazenie výsledkov analýzy.

3.3.2 Serverová časť - mikroslužby

Pre serverovú časť bol zvolený framework **Django** s programovacím jazykom **Python 3.11**. [7] Python je štandardným jazykom pre strojové učenie a počítačové videnie, disponuje rozsiahlym ekosystémom knižníc pre spracovanie multimediálneho obsahu a analýzu časových radov. Každá mikroslužba bude samostatnou Django aplikáciou, čo umožní nezávislé nasadenie a škálovanie.


3.3.3 API Gateway

Pre API Gateway bol zvolený framework **Spring Boot** s programovacím jazykom **Kotlin**. [38] Spring Boot poskytuje robustnú platformu pre správu HTTP požiadaviek, multipart file upload pre videá a koordináciu volania mikroslužieb. API Gateway bude slúžiť ako jediný vstupný bod pre mobilnú aplikáciu.

3.3.4 Počítačové videnie - MediaPipe

Najdôležitejším nástrojom pre analýzu videa bude knižnica **MediaPipe** od spoločnosti Google. [21] MediaPipe je open-source framework určený pre real-time spracovanie multimediálneho obsahu. V navrhnutom riešení bude využitý modul **MediaPipe Pose**, ktorý dokáže detekovať 33 kľúčových bodov ľudského tela v každom snímku videa. MediaPipe bude bežať výhradne na serverovej strane v rámci Služby spracovania videa.

Nasledujúci obrázok zobrazuje všetky kľúčové body, ktoré MediaPipe Pose detekuje:



Obr. 3.3: 33 kľúčových bodov detekovaných MediaPipe Pose[21]

3.3.5 Spracovanie zvuku

Pre analýzu zvukových vlastností bude využitá knižnica **librosa**[3], ktorá je štandardným nástrojom pre audio analýzu v Pythone. Librosa poskytuje funkcie pre extrakciu výšky tónu pomocou YIN algoritmu a detekciu hlasitosti pomocou RMS energie. Pre extrakciu zvukovej stopy z videa bude využitý nástroj **ffmpeg**[11].

Pre transkripciu reči a detekciu výplňových slov bude využitý model **OpenAI Whisper**[26], moderný speech-to-text model poskytujúci presnú transkripciu slovenského aj anglického jazyka s časovými značkami na úrovni slov.

3.3.6 Analýza časových radov

Pre segmentáciu časových radov bude využitá knižnica **ruptures**[36], ktorá poskytuje implementáciu algoritmu PELT popísaného v sekcii 2.4.1. Pre numerické

výpočty bude využitá knižnica **NumPy** a pre vizualizáciu výsledkov **matplotlib**.

3.3.7 Databáza

Pre ukladanie dát bude využitá relačná databáza **PostgreSQL**[32], ktorá zabezpečuje ACID vlastnosti a podporuje efektívne ukladanie štruktúrovaných dát (kľúčové body tela a detekované slová). Pre súborové úložisko videí bude využitý súborový systém servera. PostgreSQL bude rozšírené o **TimescaleDB**[33] pre efektívnejšie narábanie s časovými radmi.

3.3.8 Kontajnerizácia

Pre nasadenie a orchestráciu služieb budú využité nástroje **Docker** a **Docker Compose**[8], čo zabezpečí reprodukovateľné prostredie a zjednoduší deployment na rôzne platformy.

3.4 Architektúra riešenia

Nakoľko každá detekovaná dimenzia prezentačných schopností si vyžaduje odlišný prístup k spracovaniu dát, navrhujem **mikroslužbovú architektúru**, kde každá mikroslužba zodpovedá za jednu skupinu súvisiacich analýz. Dôvodom použitia mikroslužieb je jednoduchosť pridávania nových detekcií bez zásahu do existujúcich komponentov a technologická voľnosť pri prípadnom rozšírení systému.

3.4.1 Komponenty systému

- **Mobilná aplikácia (Flutter)** - používateľské rozhranie pre nahrávanie videí a zobrazenie výsledkov analýzy

- **API Gateway (Spring Boot/Kotlin)** - vstupný bod systému, ktorý smeruje požiadavky mobilnej aplikácie na príslušné komponenty (orchestrátor analýzy alebo spracovanie videa). Gateway neobsahuje žiadnu analytickú logiku — jeho úlohou je výhradne smerovanie a správa HTTP požiadaviek. Architektúra Gateway zároveň vytvára základ pre budúce rozšírenie o autentifikáciu a vyvažovanie záťaže.
- **Služba spracovania videa (Django/Python)** - extrakcia kľúčových bodov tela pomocou MediaPipe Pose a spracovanie video súborov
- **Služba spracovania zvuku (Django/Python)** - extrakcia zvukovej stopy z videa, spolu s úpravou vzorkovacej rýchlosti a redukciou šumu
- **Služba analýzy očného kontaktu (Django/Python)** - analýza smeru pohľadu prezentujúceho. Analýza bude obsahovať:
 - Heatmapu rozloženia pohľadu počas prezentácie
 - Časové úseky, kedy sa prezentujúci nepozeral do publika, z pohľadu systému sa tým rozumie pozeranie mimo kamery
 - Časové úseky, kedy sa príliš dlho pozeral prezentujúci na jedno miesto
 - Detekciu kritických bodov zmien v miere očného kontaktu
- **Služba analýzy pohybov rúk (Django/Python)** - analýza gestikulácie, ktorá bude obsahovať:
 - Časové úseky nedostatočnej gestikulácie
 - Časové úseky nadmerného pohybu rúk
 - Detekciu kritických bodov zmien v intenzite gestikulácie
- **Služba analýzy pohybov bokov (Django/Python)** - detekcia kývania

bokov zo strany na stranu počas prezentácie

- **Služba analýzy výplňových slov (Django/Python)** - analýza používania výplňových slov, ktorá bude obsahovať:
 - Konkrétne miesta, kedy prezentujúci povedal výplňové slovo
 - Detekciu kritických bodov zmien v používaní výplňových slov
- **Služba analýzy výšky hlasu (Django/Python)** - detekcia monotónnosti hlasu analýzou variácie základnej frekvencie
- **Služba analýzy hlasitosti (Django/Python)** - detekcia úsekov s príliš tichým alebo príliš hlasným prejavom
- **Orchestrátor analýz (Django/Python)** - centrálna služba zodpovedná za riadenie toku celkovej analýzy. Po prijatí požiadavky z API Gateway spustí paralelne všetky analytické mikroslužby, čaká na ich výsledky, agreguje ich a odovzdá hodnotiacej službe.
- **Hodnotiaca služba (Django/Python)** - agregácia výsledkov všetkých analytických mikroslužieb do jednotného hodnotenia prezentácie. Každá dimenzia (hlas, plynulosť reči, pohyb tela, očný kontakt) dostane čiastkové skóre a celkové hodnotenie bude váženým súčtom týchto skóre. Systém prechádza dvoma verziami hodnotiaceho modelu: **Model v1** využíva počiatočné váhy dimenzií odvodené z predpokladov vychádzajúcich z analýzy. Tieto váhy slúžia ako východiskový bod, ktorý je následne overovaný a kalibrovaný výsledkami výskumnej štúdie popísanej v kapitole 5. **Model v2** nahradí pôvodné váhy odvodenými hodnotami zo štúdie, pričom zhoda modelu s ľudskými hodnoteniami je vyjadrená Spearmanovou rank koreláciou. Súčasťou výstupu sú aj textové odporúčania s temporálnou lokalizáciou problémov, napríklad či sa jav vyskytoval počas celej prezentácie alebo iba v nejakej jej

časti

- **Segmentačná služba (Django/Python)** - zdieľaná mikroslužba implementujúca detekciu kritických bodov zmien v časových radoch pomocou algoritmu PELT. Analytické mikroslužby jej posielajú časový rad spolu s voľbou metódy (priemer, trend alebo štandardná odchýlka) a dostanú späť detekované body zmien. Centralizácia tejto funkcionality zabezpečuje, že prípadná zmena parametrov segmentácie sa prejaví konzistentne vo všetkých analytických mikroslužbách.
- **Služba transkripcie reči (Django/Python)** - automatická transkripcia reči pomocou OpenAI Whisper s časovými značkami na úrovni slov
- **Databáza (PostgreSQL/TimescaleDB)** - ukladanie pozícií tela, záznamov nahratých videí a slov získaných z Whisper transkripcie
- **Súborové úložisko** - ukladanie nahratých video súborov a príslušných spracovaných audio súborov

3.4.2 Mapovanie požiadaviek na komponenty


Pre prehľadnosť uvádzam tabuľku, ktorá mapuje funkčné požiadavky na konkrétne mikroslužby zodpovedné za ich implementáciu.

Požiadavka	Zodpovedná mikroslužba
Detekcia očného kontaktu a sledovanie smeru pohľadu	Služba analýzy očného kontaktu
Detekcia pohybu bokov (tancovanie)	Služba analýzy pohybov bokov
Detekcia pohybov rúk a gestikulácie	Služba analýzy pohybov rúk
Detekcia monotónnosti hlasu	Služba analýzy výšky hlasu
Detekcia hlasitosti hlasu	Služba analýzy hlasitosti
Detekcia výplňových slov v reči	Služba analýzy výplňových slov
Detekcia kritických bodov zmien v časových radoch	Segmentačná služba
Koordinácia paralelného spracovania analýz	Orchestrátor analýz
Generovanie celkového hodnotenia a odporúčaní	Hodnotiaca služba
Transkripčia reči pre detekciu výplňových slov	Služba transkripcie reči
Extrakcia kľúčových bodov tela z videa	Služba spracovania videa
Extrakcia a normalizácia audio signálu	Služba spracovania zvuku

Tabuľka 3.1: Mapovanie funkčných požiadaviek na komponenty systému

3.4.3 Komponentový diagram

Pre celkový obraz systému som pripravil nasledujúci komponentový diagram, ktorý zobrazuje všetky vyššie spomínané komponenty.




Obr. 3.4: Komponent diagram riešenia

Vo vrchnej časti tohto diagramu sa nachádza mobilná aplikácia, ktorá sa dopytuje na API gateway, ktorá preposiela požiadavky do orchestrátorov spracovania a analýzy. V pravej časti sa nachádza časť systému, ktorá zodpovedá spracovaniu videa, zatiaľ čo ľavá strana obsahuje všetky mikroslužby pre analýzu videí. Služby medzi sebou komunikujú pomocou REST api. V spodnej časti je ešte zobrazené súborové úložisko a databáza, kde sa ukladajú dáta o nahrávkach, ako aj nahrávky samotné.


Pre pochopenie som vytvoril sekvenčný diagram, ktorý znázorňuje interakciu používateľa so systémom pri nahrávaní nového videa a jeho automatickým spracovaním na strane servera. Pre jednoduchšie pochopenie diagramu som zjednotil

mikroslužby spracovania do jednej čiary života. Pod týmto označením teda môžete chápať mikroslužbu pre spracovanie videa, zvuku alebo transkripcie. Tieto služby sa spustia všetky naraz v momente vytvorenia záznamu videa v databáze. Dôležité v tomto diagrame je si všimnúť asynchrónne volania medzi jednotlivými mikroslužbami. Výsledkom tohto spracovania bude video uložené v úložisku na serveri, všetky kľúčové body tela uložené v databáze a audio súbor so vzorkovacou rýchlosťou 16 kHz.



Obr. 3.5: Natočenie a spracovanie videa

Spracovanie videa a zvuku môže trvať niekoľko minút v závislosti od dĺžky prezentácie. Systém poskytuje informácie o aktuálnom stave spracovania videa, zvuku a transkriptu, takže používateľ vie sledovať priebeh bez čakania naslepo. Po dokončení všetkých fáz predspracovania môže používateľ spustiť celkovú analýzu prezentácie. Predspracovanie je najdlhšia fáza — samotná analýza bude synchronná a výrazne rýchlejšia. Pri celkovej analýze požiadavka smeruje na orchestrátor analýz, ktorý spustí všetky analytické mikroslužby paralelne, výsledky spojí a vráti ich spolu s hodnotením z zodnotiacej mikroslužby. Nasledujúci sekvenčný diagram zobrazuje tok celkovej analýzy, kde si pod analyzačnou mikroslužbou môžete predstaviť jednu z analyzačných mikroslužieb.



Obr. 3.6: Príklad analyzovania očného kontaktu

Implementácia riešenia

V tejto kapitole podrobne popisujem implementáciu navrhnutého systému, kľúčové algoritmy, dátové štruktúry a technické riešenia použité pri realizácii jednotlivých komponentov.

Kľúčovým rozdielom oproti existujúcim riešeniam (kapitola 2) je prepojenie implementácie s výskumom. Váhy hodnotiaceho modelu nie sú nastavené intuitívne — sú odvodené z výsledkov používateľskej štúdie popísanej v kapitole 5. Štúdia odhalila, že hlas má dominantný vplyv na vnímanie kvality prezentácie ($\beta = 0,843$), čo sa priamo premietlo do váhy 37 % pre dimenziu hlas a do redukcie váhy pohybu tela z pôvodných 25 % na 9 %. Taktiež nález o rovnomerne rozložených výplňových slovách (H2.1) motivoval zavedenie distribučnej penalizácie v modeli v3.

Konfigurovateľné parametre všetkých analytických mikroslužieb (prahy detekcie, veľkosti okien, minimálne trvanie udalostí a pod.) boli nastavené empiricky. Pre tento účel bola zostavená sada kalibračných videí, v ktorých bol zámerný výskyt jednotlivých negatívnych javov (pohyb bokov, absencia gestikulácie, monotónny hlas a pod.) zreteľne prítomný. Parametre boli iteratívne upravované až kým detekcia na kalibračných videách nevykazovala správne výsledky. Takto odvodené hodnoty sú v texte uvádzané ako predvolené hodnoty konfigurácie.

4.1 Spracovanie videa

Spracovanie videa je riešené v rámci **mikroslužby spracovania videa**, ktorá má za úlohu spracovať video a získať z neho dáta, ktoré následne ostatné mikroslužby budú používať. Pre detekciu polohy tela v každom snímku videa využívam knižnicu **MediaPipe Pose** od spoločnosti Google. MediaPipe je schopný detekovať 33 kľúčových bodov ľudského tela bez potreby špeciálneho hardvéru.[21]

4.1.1 Použité kľúčové body


MediaPipe Pose poskytuje nasledujúce kľúčové body relevantné pre moju analýzu:

- **Tvár:** nos, ľavé oko, pravé oko, ľavé ucho, pravé ucho
- **Trup:** ľavé rameno, pravé rameno, ľavý bok, pravý bok
- **Ruky:** ľavý lakeť, pravý lakeť, ľavé zápästie, pravé zápästie

Každý kľúčový bod obsahuje:

- **x, y, z súradnice** — normalizované pozície v 3D priestore
- **visibility** — confidence score (0–1) indikujúci viditeľnosť bodu

Pre vizualizáciu zároveň táto služba generuje obrázky s kostrou, ktoré si môžem po spracovaní pozrieť.



Obr. 4.1: Príklad detekcie kľúčových bodov tela MediaPipe Pose

4.1.2 Nastaviteľné parametre

Táto mikroslužba ponúka úpravu niekoľkých parametrov, a to konkrétne:

- **min_detection_confidence**: Predstavuje minimálnu mieru viditeľnosti pózy na to, aby vedel model úspešne detekovať kľúčové body
- **min_tracking_confidence**: Predstavuje minimálnu mieru viditeľnosti pózy pre pokračovanie sledovania medzi rámcami
- **model_complexity**: Komplexita modelu od 0 do 3, ktorá určuje, ako bude model presný. Vyššie čísla znamenajú presnejší model, ale pomalšie spracovanie
- **frame_interval**: Predstavuje číslo v sekundách, koľko krát za sekundu spracuje model obrázok videa

- **max_video_duration:** Maximálna dĺžka videa v sekundách

Pri konfigurácii týchto parametrov som vyhotovil niekoľko konfiguračných videí a sledoval som presnosť detekcie, ako aj to, či je interval rámcov dostatočný. To či je dostatočný som rozhodoval hlavne pri rýchlych pohyboch rúk, ktoré majú medzi rámcami najväčšie zmeny. Po testoch na videách som sa rozhodol použiť tieto hodnoty parametrov:

- min_detection_confidence: 0.7
- min_tracking_confidence: 0.5
- model_complexity: 1
- frame_interval: 0.1
- max_video_duration: 1800 (30 minút)

4.1.3 Postup extrakcie


Extrakcia kľúčových bodov prebieha v nasledujúcich krokoch:

1. Najprv sa načíta video súbor
2. Systém podľa parametra frame_interval a FPS videa vypočíta, ktorý každý snímok zanalizuje
3. Pre každý snímok sa vykoná:
 - Konverzia z BGR do RGB farebného priestoru (vyžadované MediaPipe)
 - Spustenie MediaPipe Pose detekcie
 - Extrakcia 33 kľúčových bodov s ich súradnicami a viditeľnosťou
 - Uloženie kľúčových bodov do dátovej štruktúry s časom vo videu

4. Kľúčové body tela sú uložené do databázy spolu s indexom a časom

4.2 Spracovanie zvuku

Za predspracovanie zvuku je zodpovedná mikroslužba **spracovania zvuku**. Audio stopa je extrahovaná z nahratého videa pomocou nástroja **ffmpeg** ihneď po odoslaní videa. Na rozdiel od spracovania videa sa do databázy nezapisujú žiadne surové dáta. Namiesto toho sa výsledný audio súbor vo formáte WAV uloží a bude používaný inými mikroslužbami. Služba taktiež generuje vizualizáciu amplitúdy, ktorú získa z videa.



Obr. 4.2: Príklad amplitúdy zvuku získanej z videa

4.2.1 Vzorkovacia rýchlosť

Vzorkovacia rýchlosť (sample rate) reprezentuje počet meraných vzoriek za sekundu. Rôzne nahrávače zariadenia môžu mať rozdielnu vzorkovaciu frekvenciu (44.1 kHz, 48 kHz, atď.).

Pre zabezpečenie konzistencie analýzy vykonávam resampling všetkých audio sú-

borov na frekvenciu **16 kHz**. Túto hodnotu som zvolil na základe priemyselných štandardov pre speech processing a na základe analýzy, ktorá je popísaná v kapitole analýza problematiky. Pre flexibilitu riešenia som sa ale rozhodol tento parameter zmeniť na nastaviteľný pomocou premenných prostredia.

4.2.2 Redukcia šumu

Mikroslužba obsahuje voliteľnú implementáciu redukcie šumu pomocou knižnice **noisereduce**. Je využívaný stacionárny režim (**stationary=True**), ktorý odhaduje profil šumu na základe frekvenčných zložiek stabilných naprieč celou nahrávkou — napríklad hum mikrofónu alebo vzduchový šum. Intenzita potlačenia šumu je riadená parametrom **prop_decrease**: nižšia hodnota zaručí, že monotónne úseky reči nebudú chybné potlačené spolu so šumom. Redukcia aj intenzita potlačenia sú konfigurovateľné cez premenné prostredia. Výsledný čistejší signál zlepšuje presnosť transkripcie aj analýzy výšky hlasu.

4.2.3 Bitová hĺbka

Bitová hĺbka definuje presnosť merania amplitúdy zvukového signálu. Používam fixne **16-bit PCM**, čo poskytuje dostatočnú presnosť pre analýzu reči (96 dB dynamický rozsah) pri rozumnej veľkosti súboru. Pre porovnanie, 8-bit by poskytoval len 48 dB dynamický rozsah, čo by bolo nedostatočné pre detekciu jemných zmien v hlasitosti.

4.3 Transkripcia reči

Transkripcia reči je vyčlenená do samostatnej mikroslužby **Transcript Processing**, ktorá spracúva audio súbor a ukladá slová s časovými značkami do databázy.

Táto separácia umožňuje nezávislé spúšťanie transkripcie a jej opakované využitie viacerými analytickými službami.

4.3.1 Whisper model

Pre transkripciu využívam model **OpenAI Whisper**[26]. Whisper automaticky detekuje jazyk (slovenčina, angličtina) a poskytuje časové značky na úrovni slov, čo je nevyhnutné pre presnú lokalizáciu výplňových slov v čase. Konkrétna veľkosť modelu je konfigurovateľná — predvolená hodnota je `medium`, ktorá poskytuje výborný pomer medzi rýchlosťou a presnosťou transkripcie.

```
model = whisper.load_model(self.config['whisper_model'])
result = model.transcribe(audio_path, word_timestamps=True)
```

Po získaní transkriptu je každé slovo získané z transkripcie uložené do databázy s nasledujúcimi atribútmi:

- **word** — transkribovaný text slova
- **start_time, end_time** — časové ohraničenie v sekundách s presnosťou na 2 desatinné miesta
- **probability** — confidence score Whisper modelu (0–1)

Tieto hodnoty sa následne používajú pri detekcii výplňových slov.

4.4 Detekcia monotónnosti


Pitch (alebo teda výška tónu) reprezentuje základnú frekvenciu hlasu (F0)[19]. Analýzu využívania výšky hlasu spracúva mikroslužba **Pitch Analysis**. Pre extrakciu pitch využívam knižnicu `librosa` a **YIN algoritmus**, ktorý je robustný voči šumu a poskytuje presné výsledky pre ľudský hlas:

```

pitches = librosa.yin(
    audio_data,
    fmin=50,          # Hz - spodná hranica pre ľudský hlas
    fmax=300,         # Hz - horná hranica pokrývajúca mužský aj ženský hlas
    frame_length=1600,
    hop_length=800
)

```

Pre príklad som taktiež pripravil graf zobrazujúci pitch hlasu. Prázdné časti sú tie, kedy výška hlasu nemohla byť získaná, napríklad keď prezentujúci mal pauzu. Žltou farbou je zobrazený detekovaný segment monotónnosti.



Obr. 4.3: Príklad výšky tónu získaného zo zvuku

Surový výstup YIN algoritmu je pred ďalším spracovaním vyhladzovaný **mediánovým filtrom** s konfigurovateľnou veľkosťou okna (`median_filter_size`). Mediánový filter potláča jednorámové výkyvy a impulsné chyby YIN, ktoré by inak mohli skresliť detekciu monotónnych segmentov.

Následne sú snímky klasifikované ako **ozvučené alebo neozvučené** na základe

dvoch kritérií: RMS energia snímku musí presiahnuť konfigurovateľný prah (`energy_threshold`) a detekovaná pitch musí byť aspoň 70 Hz. Snímky nespĺňajúce tieto podmienky sú nahradené hodnotou NaN a nevstupujú do štatistik.

Z takto upraveného signálu následne detekujem monotónnosť. Veľkosť analyzovacieho okna je odvodzovaná z konfigurovateľného parametra `monotonous_window_ms` a vzorkovacej rýchlosti. Pre každé okno sa počítajú štatistiky iba z ozvučených snímok:

- **Štandardnú odchýlku** σ_{pitch}
- **Rozsah:** $range_{pitch} = \max(pitch) - \min(pitch)$

Ak σ_{pitch} klesne pod konfigurovateľný prah `monotonous_std_threshold` alebo $range_{pitch}$ pod `monotonous_range_threshold`, segment je označený ako monotónny. Krátke monotónne segmenty (pod `monotonous_min_duration_ms`) sú filtrované, susedné segmenty oddelené medzerou do `monotonous_merge_gap_ms` sú zlučované. Týmto vyhodím krátke detekcie (často iba šum) a reálne detekcie spojím, nech mám jeden veľký segment.

4.5 Analýza hlasitosti


Rovnako ako pre pitch, hlasitosť obsluhuje samostatná mikroslužba **Volume Analysis**. Pre detekciu hlasitosti používam **RMS (Root Mean Square) energiu**, ktorá reprezentuje priemernú amplitúdu signálu v danom časovom okne:

```
rms = librosa.feature.rms(y=audio_data, frame_length=2048, hop_length=800)
```

Aby analýza nebola závislá na vzdialenosti mikrofónu od prezentujúceho, prevádzam RMS energiu na jednotku **dBFS** (decibely voči plnej škále), kde 0 dBFS predstavuje maximálnu možnú amplitúdu.

Systém využíva trojúrovňové adaptívne prahy a to na ticho, príliš tiché a príliš hlasné rozprávanie. Najprv je vypočítaná **úroveň ticha** ako 10. percentil všetkých dBFS hodnôt nahrávky navýšený o 6 dB — snímky pod touto hodnotou sa považujú za ticho a nevstupujú do ďalšej analýzy. Z ozvučených snímkov (nad úrovňou ticha) je určená **referenčná úroveň hlasu prezentujúceho** ako 75. percentil ich dBFS hodnôt, ktorá reprezentuje typickú hlasitosť pre prezentujúceho v nahrávke a jeho mikrofónu. Od tejto referencie sú odvodené dva adaptívne prahy: **príliš tichý** a **príliš hlasný**, pričom vzdialenosti od referencie sú konfigurovateľné cez parametre `soft_margin_db` a `loud_margin_db`. Tento prístup zaručuje, že hodnotenie hlasitosti nie je absolútne, ale relatívne voči konkrétnej nahrávke, mikrofónu a rečníkovi. Síce tento prístup nevyrieši vzdialenosť od mikrofónu, poskytne ďaleko lepšie výsledky ako keby sa mal systém riadiť iba pomocou RMS energie.

Nasledujúci obrázok ukazuje príklad detekcie tichého rozprávania na začiatku prezentácie. Modrou je označený segment ako ticho.



Obr. 4.4: Príklad hlasitosti získanej zo zvuku

4.6 Detekcia výplňových slov

Mikroslužba **Filler Words Analysis** detekuje výplňové slová z dvoch zdrojov: transkriptu reči a priamej analýzy pitch signálu. Výsledky sú kombinované do jednotného zoznamu s časovými značkami.

4.6.1 Detekcia slovných výplňových slov

Slovné výplňové slová sú detekované z transkriptu uloženého v databáze mikroslužbou transkripcie. Pre každé slovo s dostatočnou istotou (`min_word_probability`) je overené, či zodpovedá niektorému zo slov v preddefinovanom zozname pre slovenčinu a angličtinu:

- **Slovenské:** ehm, eh, emm, hm, hmm, teda, jako, takže, vlastne, viete
- **Anglické:** uh, um, hmm, like, you know, so, actually, basically, literally

Detekcia prebieha pomocou regulárnych výrazov s ohraničeniami slov:

```
pattern = r'\b' + re.escape(filler) + r'\b'
```

Využitím časových značiek na úrovni slov z Whisper modelu je každé detekované slovo lokalizované v čase s presnosťou na úroveň slova.

4.6.2 Detekcia neverbálnych zvukov (*uhh*)

Neverbálne výplňové zvuky typu *uhh* predstavujú osobitný problém — Whisper ich transkribuje nespoľahlivo, pretože nejde o plnohodnotné slová. Whisper nebol dizajnovaný na detekciu týchto zvukov. Preto je pre ich identifikáciu využitý odlišný prístup: priama analýza zvukového signálu.

Zvuk *uhh* má charakteristickú akustickú vlastnosť: ide o predĺžený vokál, pri ktorom prezentujúci drží takmer rovnaký tón po dobu niekoľkých stotín sekundy. Na rozdiel od bežnej reči, kde sa tón neustále mení, je pitch pri *uhh* mimoriadne stabilný. Algoritmus teda prechádza časovým radom pitch hodnôt posuvným oknom a hľadá úseky, kde štandardná odchýlka pitch klesne pod konfigurovateľný prah pri súčasne dostatočnom podiele ozvučených snímkov.

Ako doplnkové kritérium sa sleduje, ako rýchlo sa mení samotný zvuk medzi susednými snímkami. Pri bežnej reči sa zvukový obsah mení každú chvíľu — striedajú sa rôzne hlásky, akcenty a dynamika. Pri predĺženom *uhh* zvuk zostáva takmer rovnaký. Táto rýchlosť zmeny zvuku sa nazýva **spektrálny tok** a vypočíta sa ako:

$$flux_i = \sqrt{\sum_k (|X_i[k]| - |X_{i-1}[k]|)^2} \quad (4.1)$$

kde $X_i[k]$ je amplitúda k -tej frekvencie v snímku i (Fourierova transformácia s Hanningovým oknom).[4] Nízka hodnota toku znamená, že zvuk je stabilný a pravdepodobne ide o prolongovaný vokál.

Kandidátny úsek je prijatý ako detekovaný *uhh* zvuk ak spĺňa obe kritériá — stabilný tón aj stabilný zvukový obsah — a jeho trvanie sa nachádza v rozmedzí $[d_{min}, d_{max}]$.

Nasledujúci graf zobrazuje vyznačených kandidátov a priebeh spektrálneho toku. Všimnite si, že výška hlasu (horná časť) je takmer konštantná pre kandidátov a spektrálny tok (spodná časť) má síce viacerých kandidátov, no iba prvý má nízku hodnotu. Práve takýto kandidát bude vybraný ako výplňový zvuk.




Obr. 4.5: Príklad detekcie výplňového slova uhh

4.6.3 Identifikácia úsekov so zvýšenou hustotou výplňových slov

Okrem celkových štatistík mikroslužba identifikuje časové úseky prezentácie s nadmerne koncentrovanými výplňovými slovami, čo súvisí s výskumnou otázkou RQ2 o vplyve distribúcie na vnímanie prezentácie (kapitola 5). Algoritmus využíva **bottom-up segmentáciu** popísanú v sekcii 2.4.1:

1. Prezentácia je rozdelená do fixných časových okien (predvolene 10 sekúnd). Pre každé okno sa spočíta počet výplňových slov a prepočíta sa na jednotný ukazovateľ — výskyty za minútu (napr. 3 výplňové slová v 10-sekundovom okne = 18 výskytov/min). Tým sú všetky okná porovnateľné bez ohľadu na dĺžku.
2. Susedné okná s podobnou hustotou sa postupne zlučujú do väčších úsekov. Za podobné sa považujú také, ktorých hustoty sa nelíšia viac, ako je typická variabilita hustôt v danej nahrávke — nahrávky so stabilným výskytom výplňových slov sa teda zlučujú voľnejšie ako nahrávky s veľkými výkyvmi. Zlučovanie sa zastaví, keď by ďalší krok spojil úseky, ktoré sú od seba príliš odlišné.
3. Výsledné úseky, kde je priemerná hustota viac ako dvojnásobkom celkového priemeru nahrávky, sú označené ako **kritické zóny** — miesta s nezvyčajne vysokou koncentráciou výplňových slov.


Výstupom sú časové úseky so zvýšenou koncentráciou výplňových slov vrátane pomeru ich hustoty voči celkovému priemeru. Pre každú nahrávku sú ďalej vypočítané štatistiky: celkový počet výplňových slov, frekvencia na minútu a najčastejšie použité slovo.



Obr. 4.6: Príklad koncentrácií výplňových slov

4.7 Detekcia očného kontaktu

Eye Contact Analysis mikroslužba analyzuje pohľad prezentujúceho voči publiku, ktorý predstavuje kamera, konkrétne jej stred. Implementácia je založená na výpočte uhlov hlavy z kľúčových bodov tváre. Táto služba tiež generuje pomocné grafy a heatmapu, ktorá dovoľuje detailnejšiu analýzu tohto javu a dáva používateľovi jasnú predstavu o tom, kde sa pozeral počas prezentovania, ako aj údaje o natočení hlavy a otočenie chrbtom.



Obr. 4.7: Heatmapa pohľadu a priebehy uhlov hlavy

4.7.1 Výpočet uhlov hlavy

Yaw uhol reprezentuje horizontálne otáčanie hlavy (doľava/doprava). Základná myšlienka je nasledovná: keď sa prezentujúci pozerá priamo do kamery, obe uši sú od nej rovnako ďaleko. Keď sa otočí napravo, pravé ucho sa od kamery vzdiali a ľavé priblíži. MediaPipe poskytuje pre každý kľúčový bod aj hĺbkovú súradnicu

(z), takže stačí zmerať rozdiel hĺbok uší a previesť ho na uhol:

```
ear_image_dist = sqrt(  
    (right_ear.x - left_ear.x)2 +  
    (right_ear.y - left_ear.y)2  
)  
delta_z_ear     = right_ear.z - left_ear.z  
yaw = degrees(atan2(delta_z_ear, ear_image_dist))
```

Yaw je 0° pri pohľade priamo do kamery, záporný pri otočení doľava a kladný pri otočení doprava. Namiesto absolútnych vzdialeností sa porovnáva hĺbkový rozdiel uší s ich vzájomnou vzdialenosťou na obrazovke, čo zaručuje správnosť aj pri rôznych vzdialenostiach prezentujúceho od kamery. Výsledný yaw je ešte vyhladzovaný mediánovým filtrom naprieč susednými snímkami, aby sa potlačil šum v z-koordinátoch MediaPipe. Počas vývoja boli testované aj iné prístupy (pomer vzdialeností nos-ucho, log-ratio), ktoré ale pri rôznych vzdialenostiach a nakloneniach kamery poskytovali nestabilné výsledky.

Pitch uhol reprezentuje vertikálne nakláňanie hlavy (hore/dole). Meria sa, kde sa nachádza nos voči stredu uší — ak je nos vyššie ako uši, prezentujúci pozerá nahor, ak nižšie, pozerá nadol.

Priamy problém nastáva, keď je kamera naklonená: to, čo je „hore“ v obraze, nemusí byť „hore“ pre prezentujúceho. Preto sa smer hore neurčuje podľa obrazovky, ale podľa orientácie tela — konkrétne kolmo na spojnicu ramien. Ak je kamera rovná, je to jednoducho vertikála; ak je kamera naklonená, referencia sa prispôsobí. Výsledný pitch teda hovorí, o koľko je nos vyššie alebo nižšie ako uši podľa tela prezentujúceho, nie podľa uhla kamery.

Výsledok je ešte normalizovaný odčítaním mediánového pitch celého videa. Media-

Pipe totiž umiestňuje nos mierne pod úroveň uší aj pri pohľade priamo do kamery — veľkosť tohto offsetu závisí od výšky a vzdialenosti kamery. Mediánová normalizácia tento offset automaticky eliminuje, takže pohľad rovno zodpovedá 0° bez potreby manuálneho nastavenia pre každú nahrávku.

4.7.2 Definícia zóny publika

Dobrý očný kontakt s publikom definujem ako pohľad v rámci zóny publika:

- **Yaw:** -40 až $+40$ (pohľad dopredu s miernym otáčaním do strán)
- **Pitch:** -15 až $+15$ (mierny pohľad hore/dole)

Tieto hodnoty sú konfigurovateľné a boli nastavené na základe testovania s reálnymi nahrávkami prezentácií.

Jav odvrátenia pohľadu nastáva, keď prezentujúci pozerá mimo zóny publika počas minimálne 1000 ms. Pre každý event zaznamenávam:

- **start_timestamp, end_timestamp** — časový úsek
- **duration_seconds** — trvanie v sekundách
- **avg_yaw, avg_pitch** — priemerné uhly (kam sa pozerá)

4.7.3 Detekcia otočenia chrbtom

Výpočet yaw uhla funguje správne, pokiaľ je tvár prezentujúceho otočená aspoň čiastočne smerom ku kamere. Ak sa však prezentujúci otočí chrbtom, nastáva problém: uši sú stále viditeľné (z bokov hlavy), ich hĺbkový rozdiel je takmer nulový a yaw by zostal blízko 0° — teda systém by si myslel, že prezentujúci sa pozerá priamo do kamery, hoci v skutočnosti stojí chrbtom.

Riešením je porovnanie hĺbkovej polohy nosa a ramien. Keď sa prezentujúci pozerá

do kamery, nos je bližšie ku kamere ako ramená. Keď sa otočí chrbtom, nos je naopak ďalej. Na základe tohto princípu snímky, kde je nos hlbšie než ramená, sú automaticky označené ako otočenie chrbtom a nevstupujú do analýzy pohľadu.

4.8 Detekcia pohybov rúk

Arm Movement Analysis mikroslužba detekuje nedostatočnú gestikuláciu a nadmernú nervóznú pohyblivosť rúk.

4.8.1 Normalizácia kľúčových bodov

Pred výpočtom kinetiky sú súradnice zápästí normalizované voči telu prezentujúceho. Stred tela je definovaný ako midpoint oboch bokov a škála je určená vzdialenosťou ramien. Normalizácia zaručuje, že vypočítané hodnoty rýchlosti sú nezávislé od vzdialenosti prezentujúceho od kamery.

4.8.2 Výpočet rýchlosti zápästí

Pre kvantifikáciu pohybu rúk počítam rýchlosť zápästí ako euklidovskú vzdialenosť medzi po sebe idúcimi polohami v normalizovanom priestore:

1. **Pozícia:** (x_t, y_t, z_t) — normalizované súradnice zápästia v čase t
2. **Rýchlosť:** $v_t = \sqrt{(x_t - x_{t-1})^2 + (y_t - y_{t-1})^2 + (z_t - z_{t-1})^2}$

4.8.3 Detekcia nedostatočnej gestikulácie

Nedostatočnú gestikuláciu detekujem pomocou bilaterálnej analýzy vyhladenej rýchlosti:

1. Pre každé zápästie vypočítam kľzavý priemer rýchlosti, čím sa potlačia jed-

nosnímkové výkyvy

2. Pre každý snímok otestujem, či maximálna vyhladená rýchlosť zo všetkých viditeľných zápästí klesla pod konfigurovateľný prah — detekcia je teda bilaterálna, pohyb hoci len jednej ruky stačí na to, aby snímok nebol označený
3. Ak podmienka platí pre minimálne `min_consecutive_frames` po sebe idúcich snímkov, celý úsek je označený ako chýbajúci pohyb

Nadmerná gestikulácia je detekovaná pre každú ruku zvlášť. Namiesto pevne nastavenej hranice rýchlosti sa prah počíta adaptívne z celej nahrávky — systém zistí, aká je priemerná rýchlosť pohybu rúk v danom videu, a za nadmernú považuje rýchlosť, ktorá ju výrazne presahuje. Týmto spôsobom sa prah prispôsobuje konkrétnemu prezentujúcemu: niekto prirodzene gestikuluje viac, niekto menej. Blízke udalosti tej istej ruky sú zlučované do jedného súvislého úseku a príliš krátke záblesky pohybu sú ignorované.

4.9 Detekcia pohybu bokov (tancovanie)

Hip Movement Analysis mikroslužba detekuje negatívny jav tancovania - nepotrebné pohyby bokov zo strany na stranu.

Pre analýzu pohybu bokov počítam stred medzi kľúčovými bodmi ľavého a pravého boku:


```
hip_center_x = (left_hip.x + right_hip.x) / 2  
hip_center_y = (left_hip.y + right_hip.y) / 2
```

4.9.1 Detekcia kývavého pohybu

Kývavý pohyb detekujem pomocou analýzy zmien smeru v laterálnej osi. Os (X alebo Y) je vybraná dynamicky podľa toho, ktorá má vyšší rozptyl pre dané video — táto adaptácia zaručuje správnu funkciu pri rôznych orientáciách kamery:

1. Dynamicky vyberiem laterálnu os podľa rozptylu (prezentujúci bude skôr robiť pohyby z boku na bok ako hore dole)
2. Z časového radu polôh v tejto osi vypočítam rýchlosť (prvá diferenciacia) a detekujem miesta, kde rýchlosť mení znamienko (lokálne extrémny — zmeny smeru pohybu)
3. Extrémy s amplitúdou menšou ako konfigurovateľný minimálny prah sú ignorované ako šum
4. Ak sa v pohyblivom okne nachádza minimálne `min_direction_changes` platných zmien smeru, segment je označený ako kývanie

Nasledujúca vizualizácia ukazuje video, v ktorom sa prezentujúci začal po desiatich sekundách pohybovať z boku na bok.



Obr. 4.8: Vizualizácia pohybu bokov

4.10 Segmentácia časových radov

Segmentácia je implementovaná ako samostatná mikroslužba **Segmentation**, ktorú volajú všetky analytické mikroslužby. Centralizácia segmentačnej logiky umožňuje konzistentné nastavenia a jednoduchú konfiguráciu citlivosti. Táto mikroslužba sa bude snažiť nájsť body zmien, ktoré sa následne použijú pri spätnej väzbe.

4.10.1 Algoritmus PELT

Pre detekciu bodov zmien využívam algoritmus **PELT** (Pruned Exact Linear Time)[15] implementovaný v knižnici **ruptures**[36]. PELT je exaktný offline algoritmus, ktorý hľadá body zmien minimalizovaním penalizovanej cenovej funkcie.

Mikroslužba podporuje tri cenové funkcie, z ktorých si volajúca mikroslužba môže vybrať podľa charakteru analyzovaného signálu:

- **mean** (12) — detekuje zmeny v priemere (vhodné pre pitch, hlasitosť)
- **std** (normal) — detekuje zmeny vo variancii (vhodné pre kolísavosť signálu)
- **trend** (linear) — detekuje zmeny v smere trendu (vhodné pre dlhodobé trendy)

4.10.2 Parameter citlivosti

PELT algoritmus interne pracuje s penalizačným parametrom, ktorý určuje, koľko bodov zmien nájde. Pri vysokej penalizácii nájde menej bodov, a pri nízkej viac. Keďže táto hodnota nie je intuitívna, je vystavená ako parameter **citlivosti** v rozsahu 0–1: citlivosť 0 odhalí iba veľmi výrazné body zmien, citlivosť 1 zachytí aj jemné zmeny. Každá analytická mikroslužba má vlastnú predvolenú hodnotu

citlivosti nastavenú podľa kalibračných videí.

4.10.3 Výstup segmentácie

Pre každý analyzovaný signál mikroslužba vracia:

- **change_points** — zoznam časových pozícií bodov zmien (v sekundách) pre každú metódu
- **segments** — štatistiky každého segmentu: priemer, štandardná odchýlka, minimum, maximum
- **penalty_used** — skutočne použitá penalizácia (pre reprodukovateľnosť)

4.11 Hodnotenie prezentácie

Mikroslužba **Performance** agreguje výsledky všetkých analytických mikroslužieb do jednotného hodnotenia prezentácie. Táto mikroslužba implementuje **hodnotiaci model**, ktorého parametre boli odvodené z výsledkov používateľskej štúdie popísanej v kapitole 5.

4.11.1 Štruktúra hodnotenia

Celkové hodnotenie je rozdelené do štyroch dimenzií, pričom každá je hodnotená na škále 0–100:

- **Hlas (voice)** — monotónnosť a hlasitosť, váha 37 %
- **Plynulosť (fluency)** — výplňové slová, váha 27 %
- **Pohyb tela (body)** — gestikulácia a kývanie bokov, váha 9 %
- **Očný kontakt (eye_contact)** — smer pohľadu, váha 27 %

Celkové skóre je váženým súčtom dimenzionálnych skóre. Váhy boli odvodené z normalizovaných beta koeficientov viacnásobnej lineárnej regresie ($n = 52$). V pôvodnom modeli v1 boli váhy rovnomerne rozdelené na základe predpokladov z analýzy; model v2 tieto váhy nahradil overenými hodnotami.

4.11.2 Výpočet dimenzionálnych skóre

Každá dimenzia začína na 100 bodoch a sú od nej odpočítavané penalizácie za zistené problémy.

Hlas penalizuje dve zložky:

- Monotónnosť: percentuálny podiel hlasom vypovedaných snímkov v monotónnych segmentoch (0–70 % mapuje na 0–50 bodov penalizácie)
- Hlasitosť: percentuálny podiel snímkov s príliš tichým alebo príliš hlasným prejavom (0–50 % mapuje na 0–50 bodov penalizácie)

Plynulosť penalizuje na základe frekvencie výplňových slov:

- 0–2 výplňové slová/min: bez penalizácie
- 2–5 výplňových slov/min: lineárna penalizácia 0–40 bodov
- 5+ výplňových slov/min: penalizácia 40–100 bodov

Navyše bol v modeli v3 pridaný **distribučný trest** na základe nálezu z výskumu (H2.1): rovnomerne rozložené výplňové slová sú vnímané horšie ako sústredené. Koeficient variácie ($CV = \sigma/\mu$) hustoty výplňových slov naprieč časovými oknami meria mieru rovnomernosti — nízke CV vedie k penalizácii až 7 bodov. Pôvodná hodnota 20 bodov bola na základe validácie (H3.2) znížená, pretože spôsobovala väčší rozdiel medzi V5 a V6 ako zodpovedá ľudskému vnímaniu.

4.11.3 Odporúčania

Pre každý identifikovaný problém systém generuje textové odporúčanie v slovenčine. Odporúčania sú pre každú dimenziu pevne definované a systém ich vyberie podľa toho, ktoré problémy boli detekované:

Problém	Odporúčanie
Monotónny hlas	Váš hlas bol monotónny vo veľkej časti prezentácie. Skúste viac variovať výšku hlasu, najmä pri kľúčových myšlienkach.
Nevhodná hlasitosť	Hlasitosť vášho prejavu bola často mimo optimálneho rozsahu. Snažte sa udržiavať konzistentnú, zreteľnú hlasitosť.
Výplňové slová	Používate príliš veľa výplňových slov. Namiesto výplňových slov skúste krátku pauzu — pôsobí sebaisto.
Nedostatočná gestikulácia	Vaše ruky boli po dlhú dobu takmer bez pohybu. Prírodná gestikulácia podporuje prejav a drží pozornosť publika.
Nervózna gestikulácia	Ruky ste pohybovali príliš rýchlo alebo nervózne. Skúste zámernejšiu a pomalšiu gestikuláciu.
Kývanie bokov	Počas prezentácie ste sa výrazne kývali na bokoch. Stabilný postoj zvyšuje dôveryhodnosť.
Slabý očný kontakt	Príliš často ste sa pozerali mimo publikum. Snažte sa udržiavať očný kontakt s rôznymi časťami publika.
Fixovanie pohľadu	Dlho ste sa fixovali na jedno miesto. Rozdeľujte pohľad rovnomerne po celom publiku.
Otočenie chrbtom	Otočili ste sa chrbtom k publiku. Vždy hovorte čelom k publiku, aj keď odkazujete na premietaný obsah.

Tabuľka 4.1: Zoznam odporúčaní systému

Každé odporúčanie je doplnené o **časovú lokalizáciu** — systém vyhodnotí, v ktorej časti prezentácie sa problém vyskytoval najviac (začiatok, stredná časť, koniec, alebo rovnomerne počas celej prezentácie), a túto informáciu pripojí na

koniec textu odporúčania. Napríklad: „*Prejavilo sa to najmä na začiatku prezentácie.*”

Skóre	Hodnotenie
90–100	Výborné
75–89	Dobré
60–74	Priemer
40–59	Potrebuje zlepšenie
0–39	Slabé


Tabuľka 4.2: Stupnica hodnotenia prezentácie

4.12 Mobilná aplikácia

Mobilná aplikácia pokrýva celý životný cyklus práce s nahrávkou: od nahrávania cez spustenie analýzy až po prezeranie výsledkov.

4.12.1 Nahrávanie prezentácie


Po vybratí možnosti nového videa sa otvorí obrazovka s kamerou, ktorá priebežne zobrazuje detekovanú kostru tela. Tým si môže používateľ pred samotným nahrávaním overiť, že je správne umiestnený pred kamerou a detekcia bude fungovať. Po stlačení tlačidla aplikácia odpočíta tri sekundy a začne zaznamenávať. Po skončení má možnosť video orezať — na odstránenie záverečnej časti, keď šiel kameru vypnúť — pomenovať nahrávku a odoslať ju na server.



Obr. 4.9: Obrazovky nahrávania v mobilnej aplikácii

4.12.2 Výsledky analýzy

Po dokončení analýzy na serveri aplikácia zobrazí výsledky v niekoľkých pohľadoch. Hlavná obrazovka prezentuje **celkové skóre** so slovným hodnotením (napr. Dobré, Priemer) a zoznamom textových odporúčaní doplnených o časovú lokalizáciu problému. Používateľ si môže ďalej prezrieť **štatistiky** jednotlivých dimenzií — čiastkové skóre hlasu, plynulosti, pohybu tela a očného kontaktu, spolu s konkrétnymi číslami ako počet výplňových slov alebo percentuálny podiel monotónnych úsekov. Pre vybrané dimenzie sú dostupné aj detailnejšie vizualizácie. Napríklad pri **očnom kontakte** aplikácia zobrazuje heatmapu rozloženia pohľadu počas celej prezentácie, ktorá dáva používateľovi intuitívny obraz o tom, kam počas prejavu prevažne hľadel. Všetky negatívne javy ponúkajú možnosť zobrazenia konkrétneho miesta, kde bola detekovaná chyba. Zároveň sa v zozname chýb objavujú aj miesta, kedy PELT algoritmus našiel kritickú zmenu.



Obr. 4.10: Spätná väzba z analýzy v mobilnej aplikácii

Tieto odporúčania, štatistiky, zobrazovanie časových stop vo videu, kedy spravil prezentujúci chybu tvorí základ pre tréningové prezentáčnych schopností.

Výskumná štúdia

Návrh hodnotiaceho systému vychádza z predpokladov o ľudskom vnímaní prezentácií: že jednotlivé dimenzie majú rôzny vplyv na celkový dojem a že sústredené výskyty negatívnych javov sú pre publikum relevantnejšie ako rovnomerne roztrúsené. Výskumná štúdia tieto predpoklady testuje — jej výsledky spätne validujú konkrétne dizajnové rozhodnutia systému a umožňujú kalibrovať hodnotiaci model na základe skutočného ľudského vnímania.

Prepojenie medzi hypotézami a systémom zachytáva nasledujúca tabuľka:

Hypotéza	Čo validuje v systéme
H1.1a	Oprávnenosť toho, že vizuálne a hlasové dimenzie majú dohromady vyššiu váhu ako plynulosť reči
H1.1b	Oprávnenosť hierarchie váh: vizuálne > hlasové > plynulosť
H1.2	Oprávnenosť vyššej váhy hlasu oproti plynulosti reči
H2.1	Oprávnenosť segmentačného prístupu. V tejto štúdii sa zameriavam iba na výplňové slová

Tabuľka 5.1: Prepojenie výskumných hypotéz s dizajnovými rozhodnutiami systému

5.1 Výskumné otázky a hypotézy

Štúdia sa zameriava na dve výskumné otázky:

RQ1: Majú vizuálne dimenzie (očný kontakt, pohyb tela) a hlasové dimenzie (výška hlasu, hlasitosť) väčší vplyv na vnímané celkové hodnotenie prezentácie ako plynulosť reči (výplňové slová)? Platí hierarchia negatívneho efektu na dojem

z prezentácie týchto dimenzií: vizuálne > hlasové > plynulosť?

RQ2: Je sústredený výskyt negatívneho javu v jednom súvislom bloku vnímaný respondentmi horšie ako rovnaký celkový čas javu rozloženého rovnomerne počas celej prezentácie?

Na základe týchto otázok boli definované štyri hypotézy:

- **H1.1a** — Očný kontakt, pohyby tela a vlastnosti hlasu majú spolu väčší vplyv na celkové hodnotenie prezentácie ako plynulosť reči.
- **H1.1b** — Očný kontakt a pohyby tela majú väčší vplyv na celkové hodnotenie prezentácie ako hlasové vlastnosti rečníka, ktoré sú zároveň vplyvnejšie ako výplňové slová.
- **H1.2** — Monotónnosť hlasu má väčší negatívny vplyv na celkové hodnotenie prezentácie ako výplňové slová.
- **H2.1** — Sústredený výskyt výplňových slov má väčší negatívny vplyv na celkové hodnotenie prezentácie ako ich rovnomerne roztrúsený výskyt.

5.2 Dizajn experimentu

5.2.1 Príprava videí

Pre štúdiu bola nahratá séria šiestich videí s rovnakým prezentujúcim a rovnakým obsahom. Každé video malo dĺžku približne 60 sekúnd. Videá sa líšili práve tým aspektom prezentácie, ktorý bol predmetom skúmania. Manipulácia vždy zasiahla iba jednu dimenziu, ostatné boli ponechané neutrálne.

Video	Označenie	Popis manipulácie
V1	Baseline	Neutrálna prezentácia bez zámerných chýb. Slúži ako referenčná hodnota.
V2	Zlý očný kontakt	Prezentujúci sa pozerá na poznámky a mimo kamery — simulácia absencie očného kontaktu.
V3	Pohyb bokov	Výrazné kývanie bokov zo strany na stranu počas celej prezentácie.
V4	Monotónny hlas	Prezentujúci hovorí s konštantnou výškou a rytmom hlasu, bez akejkoľvek prozódie.
V5	Výplňové slová (rovnomerne)	Výplňové slová sú rozložené rovnomerne počas celej prezentácie.
V6	Výplňové slová (sústredene)	Rovnaký celkový počet výplňových slov sústredený do strednej časti prezentácie.

Tabuľka 5.2: Prehľad videí použitých v štúdiu

5.2.2 Zber dát

Dáta boli zozbierané prostredníctvom online dotazníka (Google Forms). Respondentom bolo postupne zobrazených všetkých šesť videí v rovnakom poradí. Po každom videu hodnotili prezentujúceho na škále 0–10 v piatich kategóriach: **celkové hodnotenie**, **očný kontakt**, **pohyb tela**, **plynulosť reči** a **hlas**.

Celkový počet respondentov bol $n = 52$.

Demografické charakteristiky vzorky sú uvedené v tabuľkách 5.3 a 5.4. Vzorka zahŕňala 16 žien (30,8 %) a 36 mužov (69,2 %). Väčšinu tvorili respondenti vo vekovej kategórii 18–25 rokov (46,2 %). Z hľadiska skúseností s prezentovaním dominovali respondenti, ktorí prezentujú len výnimočne (44,2 %), nasledovaní tými, pre ktorých je prezentovanie bežnou súčasťou štúdia alebo práce (34,6 %). Vzorka pokrývala rôzne úrovne skúseností, čo zvyšuje jej reprezentatívnosť.

Charakteristika	Počet	Podiel
<i>Pohlavie</i>		
Ženy	16	30,8 %
Muži	36	69,2 %
<i>Veková skupina</i>		
18–25 rokov	24	46,2 %
26–35 rokov	12	23,1 %
36–50 rokov	14	26,9 %
51 a viac rokov	2	3,8 %

Tabuľka 5.3: Demografické charakteristiky respondentov

Skúsenosti s prezentovaním	Počet	Podiel
Prezentovanie je bežná súčasť štúdia/práce	18	34,6 %
Prezentuje výnimočne	23	44,2 %
Dlhšie neprezentoval	10	19,2 %
Aktívne sa venuje prezentovaniu	1	1,9 %

Tabuľka 5.4: Skúsenosti respondentov s prezentovaním

5.3 Štatistické metódy

Pre overenie hypotéz boli použité nasledujúce štatistické metódy, implementované v jazyku Python s využitím knižnice `pingouin`[37]:

- **Viacnásobná lineárna regresia** — štandardizované beta koeficienty vyjadrujúce relatívny vplyv každej dimenzie na celkové hodnotenie. Dáta boli pred regresiou štandardizované (z-score).
- **Pearsonova korelácia per respondent** — pre každého respondenta bola vypočítaná korelácia medzi hodnoteniami dimenzií a celkovým hodnotením naprieč šiestimi videami. Takto vzniklo 52 párov hodnôt pre každú dimenziu.
- **Párový t-test** — porovnanie priemerov dvoch skupín merané na tých istých respondentoch. Použitý pre H1.1, H1.2 a H2.1.

- **Wilcoxonov test** — neparametrická alternatíva k párovému t-testu. Slúži ako robustnostná kontrola pri porušení normality.
- **Cohenovo d** — veľkosť efektu (malý: $|d| < 0,2$, stredný: $|d| \approx 0,5$, veľký: $|d| > 0,8$).
- **Repeated Measures ANOVA** s Greenhouse-Geisserovou korekciou — testuje, či existujú štatisticky významné rozdiely medzi všetkými šiestimi videami súčasne. Post-hoc párové testy s Bonferroniho korekciou identifikujú konkrétne rozdielne dvojice.
- **Spearmanova rank korelácia** — porovnanie poradia videí podľa modelu s poradím podľa ľudských hodnotení.

Pred spustením RM ANOVA boli overené jej predpoklady: normalita pomocou Shapiro-Wilkovho testu, sféricita pomocou Mauchlyho testu a prítomnosť odľahlých hodnôt podľa IQR pravidla. Normalita bola mierne porušená pre V1 ($p < 0,001$) a V5 ($p = 0,047$), čo je pri $n = 52$ akceptovateľné vzhľadom na Centrálnu limitnú vetu. Sféricita bola porušená ($W = 0,476$, $p < 0,001$, $\varepsilon = 0,780$), preto bola použitá Greenhouse-Geisserova korekcia.

5.4 Výsledky

Tabuľka 5.5 poskytuje stručný prehľad všetkých testovaných hypotéz a ich výsledkov. Podrobné štatistiky a interpretácia sú uvedené v nasledujúcich podkapitolách.

Hypotéza	Čo testuje	Výsledok	p-hodnota
H1.1a	Vizuálne+hlasové majú väčší vplyv ako plynulosť	Zamietnutá	0,037
H1.1b	Hierarchia: Vizuálne > Hlasové > Plynulosť	Čiastočná	<0,001
H1.2	Monotónnosť vnímaná horšie ako fillery	Nepodporená	0,870
H2.1	Sústredené fillery horšie ako rovnomerne	Zamietnutá	<0,001

Tabuľka 5.5: Prehľad hypotéz a ich výsledkov

5.4.1 H1.1 — Vplyv dimenzií na celkové hodnotenie

Ako prvý krok boli odhadnuté relatívne váhy jednotlivých dimenzií pomocou viacnásobnej lineárnej regresie. Dáta boli pred regresiou štandardizované (z-skóre), takže výsledné beta koeficienty sú priamo porovnateľné naprieč dimenziami:

Dimenzia	Beta koeficient
Hlas	0,843
Očný kontakt	0,586
Plynulosť	0,574
Pohyb tela	0,250

Tabuľka 5.6: Štandardizované beta koeficienty z lineárnej regresie

Empirická hierarchia vplyvu na celkové hodnotenie je teda **hlas > očný kontakt > plynulosť > pohyb tela**, čo je v rozpore s predpokladanou hierarchiou vizuálne > hlasové > plynulosť.

H1.1a

Nulová hypotéza: Vizuálne a hlasové dimenzie spolu nie sú silnejším prediktorom celkového hodnotenia ako plynulosť reči — teda rozdiely medzi skupinami sú náhodné.

Metóda: Pre každého respondenta bola vypočítaná korelácia jeho hodnotení každej dimenzie s celkovým hodnotením naprieč 6 videami. Korelácie boli Fisherovou z-transformáciou prevedené do symetrického rozdelenia, čím sa umožnil párový t-test medzi skupinou (vizuálne + hlasové, priemerované) a plynulosťou. Tento prístup zohľadňuje individuálne rozdiely medzi respondentmi.

Výsledok: Párový t-test: $t = -2,143$, $p = 0,037$. Priemerná korelácia skupiny vizuálne + hlasové ($\bar{r} = 0,550$) je štatisticky signifikantne **nižšia** ako korelácia plynulosti ($\bar{r} = 0,613$). **Hypotéza H1.1a bola zamietnutá v opačnom smere** — vizuálne a hlasové dimenzie spolu nie sú silnejším prediktorom ako plynulosť. Príčinou je nízky príspevok pohybu tela ($\beta = 0,250$), ktorý strháva priemer skupiny pod úroveň plynulosti.

H1.1b

Nulová hypotéza: Medzi troma skupinami dimenzií (vizuálne, hlasové, plynulosť) nie je štatisticky významný rozdiel vo vplyve na celkové hodnotenie.

Metóda: Rovnaký prístup ako pri H1.1a — párový t-test na per-respondent koreláciách, tentokrát s dvoma porovnaniami: vizuálne vs. hlasové a hlasové vs. plynulosť.

Výsledok: Vizualne vs. hlasové: $t = -5,238$, $p < 0,001$ — hlas štatisticky signifikantne dominuje nad vizuálnymi dimenziami. Hlasové vs. plynulosť: $t = 1,457$, $p = 0,151$ — rozdiel nie je signifikantný. **Hypotéza H1.1b bola čiastočne podporená v opačnom smere** — hlas dominuje nad vizuálnymi dimenziami (potvrdené), ale poradie hlas > plynulosť nebolo štatisticky dokázané.

Metodologická poznámka — halo efekt: Respondenti hodnotili každé video vo všetkých dimenziách súčasne. V dátach sa prejavil halo efekt: keď bolo video zhoršené v jednej dimenzii, klesali aj hodnotenia ostatných dimenzií, ktoré neboli mani-

pulované (napr. V4 s monotónnym hlasom mal nižšie hodnotenie plynulosti 5,67 oproti baseline 8,18). Beta koeficienty teda čiastočne odrážajú aj tento efekt, nie len izolovaný vplyv každej dimenzie.

5.4.2 H1.2 — Monotónnosť vs. výplňové slová

Nulová hypotéza: Priemerné celkové hodnotenie videa s monotónnym hlasom (V4) sa štatisticky nelíši od hodnotenia videa s výplňovými slovami (V5).

Metóda: Priame porovnanie celkových hodnotení V4 a V5 párovým t-testom — keďže každý respondent hodnotil obe videá, eliminujú sa medziosobné rozdiely v prísnosti hodnotenia. Wilcoxonov test slúži ako robustnostná kontrola pri prípadnom porušení normality.

Výsledok: Priemerné hodnotenie $V4 = 4,40 \pm 1,91$, $V5 = 4,44 \pm 2,09$. Párový t-test: $t = -0,164$, $p = 0,870$, $d = -0,019$. Wilcoxon: $W = 386,0$, $p = 0,742$.

Hypotéza H1.2 nebola podporená — oba javy boli respondentmi hodnotené prakticky identicky. Výplňové slová boli v štúdií prítomné vo vysokej frekvencii, čo pravdepodobne spôsobilo rovnako silný negatívny dojem ako monotónny hlas.

5.4.3 H2.1 — Distribúcia výplňových slov

Nulová hypotéza: Distribúcia výplňových slov v čase nemá vplyv na celkové hodnotenie — prezentácie V5 (rovnomerne) a V6 (sústredene) budú hodnotené rovnako.

Metóda: Párové porovnanie celkových hodnotení V5 a V6 párovým t-testom a Wilcoxonovým testom. Obe videá mali identický celkový počet výplňových slov, líšili sa iba ich rozmiestnením — V5 rovnomerne po celej prezentácii, V6 sústredene

v strednej časti.

Výsledok: Priemerné hodnotenie $V5 = 4,44 \pm 2,09$, $V6 = 6,27 \pm 2,07$. Párový t-test: $t = 5,492$, $p < 0,001$, $d = 0,871$. Wilcoxon: $W = 81,0$, $p < 0,001$. 40 z 52 respondentov (76,9 %) hodnotilo V5 horšie ako V6. **Hypotéza H2.1 bola zamietnutá s opačným nálezom** — rovnomerne rozložené výplňové slová sú vnímané výrazne horšie ako sústredené. Konštantná prítomnosť výplňových slov počas celej prezentácie neposkytuje poslucháčovi žiadnu pauzu od rušivého javu. Efekt je veľký ($d = 0,871$) a robustný naprieč oboma testmi.

5.4.4 Repeated Measures ANOVA

RM ANOVA potvrdila, že medzi videami existujú štatisticky vysoko významné rozdiely: $F(5, 255) = 39,412$, $p_{GG} < 10^{-22}$, $\eta_g^2 = 0,256$ (veľký efekt). Bonferroniho post-hoc testy odhalili 12 z 15 signifikantných párov ($p < 0,05$). Nesignifikantné páry (V4 vs. V5, V2 vs. V6, V3 vs. V6) sú v súlade s ostatnými nálezmi.

RM ANOVA per dimenzia odhalila najväčší efekt pre **hlas** ($\eta_g^2 = 0,402$), nasledovaný plynulosťou ($\eta_g^2 = 0,334$) a očným kontaktom ($\eta_g^2 = 0,175$). Pohyb tela mal najmenší efekt ($\eta_g^2 = 0,050$). Tieto hodnoty sú v súlade s beta koeficientmi z regresie.

5.5 Implikácie pre systém

Výsledky štúdie boli zapracované do systému v dvoch krokoch:

Model v2 — aktualizácia váh: Pôvodné váhy dimenzií (hlas 25 %, plynulosť 20 %, pohyb tela 25 %, očný kontakt 30 %) boli nahradené váhami odvodenými z normalizovaných beta koeficientov (súčet beta = 2,24):

Dimenzia	Model v1	Model v2
Hlas	25 %	37 %
Plynulosť	20 %	27 %
Očný kontakt	30 %	27 %
Pohyb tela	25 %	9 %

Tabuľka 5.7: Porovnanie váh dimenzií medzi modelmi

Model v3 — penalizácia distribúcie výplňových slov: Na základe nálezu H2.1 bol do výpočtu skóre plynulosti pridaný distribučný trest. Prezentácia je rozdelená do 6 časových okien; koeficient variácie ($CV = \sigma/\mu$) hustoty výplňových slov určuje mieru rovnomernosti distribúcie. Nízke CV (rovnomerné rozloženie) vedie k vyššej penalizácii (max. 7 bodov).

5.5.1 Porovnanie modelov

Validita modelov bola overená Spearmanovou rank koreláciou medzi poradím 6 videí podľa systémového skóre a poradím podľa priemerných ľudských hodnotení. Spearmanova korelácia bola zvolená, pretože systémové skóre a ľudské hodnotenia sú na rôznych škálach (0–100 vs. 0–10), a preto nie je zmysluplné porovnávať absolútne hodnoty — dôležité je, či systém zoraďuje videá rovnako ako ľudia. Rank korelácia je na tento účel priamo určená.

Model	Spearman ρ	Zmena
v1 (pôvodné váhy)	0,600	—
v2 (váhy z výskumu)	0,829	+0,229
v3 (váhy + distribúcia)	0,829	0,000

Tabuľka 5.8: Spearmanová rank korelácia modelov s ľudskými hodnoteniami

Model v2 dosiahol výrazné zlepšenie oproti modelu v1 — poradie videí zodpovedá ľudskému vnímaniu výrazne presnejšie. Model v3 nezmenil celkové poradie (V5 bolo pred V6 už v modeli v2), avšak zväčšil rozdiel skóre V5 a V6 v dimenzii

plynulosť z 21,8 na 28,8 bodu. Porovnaním tohto systémového rozdielu ($\Delta_{sys} = -2,88$) s reálnym rozdielom v ľudských hodnoteniach plynulosti ($\Delta_{human} = -1,64$, párový t-test: $t = -5,864$, $p < 0,001$) vyplýva, že distribučná penalizácia je mierne agresívnejšia, ako zodpovedá ľudskému vnímaniu — systém trestá rovnomerne rozložené výplňové slová výraznejšie, ako to ľudia skutočne pociťujú. Kalibrácia tejto penalizácie ostáva predmetom ďalšieho vývoja.

Systémové skóre naprieč všetkými modelmi systematicky nadhodnocuje kvalitu prezentácie v porovnaní s ľudskými hodnoteniami (priemerný rozdiel $\approx +24$ bodov). Príčinou je, že systém deteguje len merateľné technické javy, zatiaľ čo ľudia vnímajú prezentáciu širšie — vrátane aspektov, ktoré systém neanalyzuje (nervozita, dikcia, obsah). Kalibrácia absolútnych hodnôt skóre zostáva otvorenou výzvou pre ďalší vývoj.

5.6 Validácia hodnotiaceho modelu

Tretia výskumná oblasť overuje, či poradie videí podľa systémového skóre zodpovedá poradiu podľa ľudského hodnotenia a či empiricky odvodené váhy a distribučná penalizácia túto zhodu zlepšujú.

5.6.1 H3.1 — Výskumom odvodené váhy zvyšujú zhodu modelu s ľudským hodnotením

Hypotéza: Spearmanova korelácia poradia videí bude vyššia pre model v2 (empirické váhy) ako pre model v1 (intuitívne váhy).

Výsledky sú zhrnuté v tabuľke 5.8 v predchádzajúcej sekcii. Prechod z modelu v1 ($\rho = 0,600$, $p = 0,208$) na model v2 ($\rho = 0,829$, $p = 0,042$) predstavuje nárast o $+0,229$. Model v1 nie je štatisticky signifikantný, model v2 áno. **Záver: Hypotéza**

H3.1 potvrdená.

Ako doplnková kontrola bola vykonaná leave-one-out krížová validácia (LOO-CV): pre každé z 6 videí boli váhy odvodené z regresie na zostávajúcich 5 videách a aplikované na vynechané video. Výsledná korelácia dosiahla $\rho = 0,829$ ($p = 0,042$, $MAE = 0,43$), čo naznačuje, že regresne odvodené váhy generalizujú aj mimo trénovacej vzorky.

5.6.2 H3.2 — Distribučná penalizácia presnejšie kopíruje ľudský rozdiel V5 vs. V6

Hypotéza: Absolútna chyba $|\Delta_{sys} - \Delta_{human}|$ na dimenzii plynulosť bude nižšia pre model v3 ako pre modely v1 a v2.

Ľudský rozdiel hodnotenia plynulosti V5 – V6: $\Delta_{human} = -1,64$ (párový t-test: $t = -5,864$, $p < 0,001$).

Model	Systémový Δ (V5 – V6)	$ \Delta_{sys} - \Delta_{human} $
v1	-2,18	0,545
v2	-2,18	0,545
v3	-2,88	1,245

Tabuľka 5.9: Porovnanie systémového a ľudského rozdielu V5 – V6 na dimenzii plynulosť

Záver: Hypotéza H3.2 nebola potvrdená — výsledok je opačný. Modely v1 a v2 sú výrazne bližšie k ľudskému rozdielu ($|chyba| = 0,545$) ako model v3 ($|chyba| = 1,245$). Distribučná penalizácia zveličuje rozdiel medzi rovnomerne a sústrednene rozloženými výplňovými slovami nad mieru, akú ľudia skutočne vnímajú. Smer efektu (V5 vnímané horšie ako V6) je zachytený správne vo všetkých troch modeloch, avšak veľkosť penalizácie v modeli v3 si vyžaduje ďalšiu kalibráciu.

5.6.3 Obmedzenia štúdie

Fixné poradie videí. Všetci respondenti videli videá v rovnakom poradí. To môže vytvárať order effects — napríklad únava pri posledných videách alebo kontrastné efekty voči predchádzajúcemu videu. Náhodné poradie by tieto efekty eliminovalo, avšak pre 6 videí by vyžadovalo výrazne väčší počet respondentov.

Jeden prezentujúci. Všetky videá nakrútila jedna osoba, čo obmedzuje zovšeobecniteľnosť výsledkov — vplyv dimenzií môže byť čiastočne špecifický pre konkrétneho prezentujúceho. Pre potvrdenie záverov by boli potrebné videá s viacerými prezentujúcimi.

Málo videí pre validáciu modelu. Spearmanova korelácia počítaná z $n = 6$ videí je citlivá na jednotlivé body. Bootstrap intervaly spoľahlivosti pri tejto veľkosti vzorky neposkytujú konfirmačnú informáciu. Validácia na nezávislom vzorke reálnych prezentácií je predmetom ďalšieho výskumu.

Hodnotenie systému

Táto kapitola overuje systém na dvoch úrovniach: technickej presnosti detektorov a schopnosti systému pomáhať používateľom zlepšovať sa. Validácia hodnotiaceho modelu voči ľudskému vnímaniu je popísaná v kapitole 5.

6.1 Validácia detektorov

6.1.1 Metodika merania

Každý detektor bol overený na sade krátkych izolovaných scenárov (30–90 sekúnd), v ktorých bola kontrolovane manipulovaná práve jedna premenná.

Referenčné anotácie som vyhotovoval ručne pre všetky validačné videá.

Pre eventové detektory (výplňové slová) sa anotujú časové body s toleranciou ± 200 ms; pre segmentové detektory (pohyb, hlas) sa anotujú intervaly s toleranciou ± 500 ms.

Metriky sú vypočítané pomocou evaluačného skriptu, ktorý porovnáva detekované intervaly s anotáciami videa na úrovni 1-sekundových binárnych okien:

- **Precision** — podiel okien správne detekovaných z celkového počtu detekovaných okien
- **Recall** — podiel okien správne detekovaných z celkového počtu anotovaných okien

- **F1** — harmonický priemer presnosti a citlivosti; hodnota 0 ak GT existuje ale žiadna detekcia nespadá do anotovaného okna

Výsledné metriky sú priemerom hodnôt naprieč všetkými testovacími videami daného detektora. Akceptačné prahy sú stanovené pragmaticky pre účely diplomovej práce: minimálny $F1 = 0,70$ pre vizuálne detektory, $F1 = 0,75$ pre akustické a textové detektory.

6.1.2 Testovací materiál

Detektor	N scénárov	Popis manipulácií
Očný kontakt	2	Dlhé odvrátenie pohľadu (>1 s); otočenie chrbtom k publiku
Pohyby rúk	4	Ruky pri tele; prirodzená gestikulácia; intenzívna gestikulácia; žiadna gestikulácia
Pohyb bokov	3	Pevný stoj; kývanie zo strany na stranu; prešľapovanie
Monotónnosť hlasu	4	Výrazná intonácia; priemerná konverzácia; zámerne monotónne; monotónne s občasnou intonáciou
Hlasitosť	2	Konštantná hlasitosť; príliš tichý hlas v časti prezentácie
Výplňové slová	3	Bez výplňových slov; občasné (1/30 s); husté (5/30 s)

Tabuľka 6.1: Prehľad testovacích scénárov per detektor

6.1.3 Výsledky

Detektor	Jav	N	P	R	F1
volume	Príliš tichý hlas	2	0,805	1,000	0,892
hip	Kývanie bokov	3	0,844	0,917	0,874
pitch	Monotónny segment	4	0,567	0,790	0,819
eye_contact	Pozeranie mimo publika (>1 s)	2	0,746	0,778	0,750
filler_words	Detekcia výplňového slova	3	0,746	0,773	0,750
arm_movement	Nedostatočná gestikulácia	4	0,764	0,697	0,647
eye_contact	Otočenie chrbtom	2	0,800	0,400	0,400
arm_movement	Nadmerná gestikulácia	4	0,625	0,417	0,417

Tabuľka 6.2: Presnosť detektorov (priemerné metriky, bin = 1 s)

Detektory hlasitosti ($F1 = 0,892$), pohybu bokov ($F1 = 0,874$) a monotónnosti ($F1 = 0,819$ *) dosahujú najlepšie výsledky. (* Agregát pitch počítaný z videí V12 a V13; video V11 bez GT udalostí prispieva iba k priemeru presnosti.) Detektor očného kontaktu — pohľad mimo publika ($F1 = 0,750$) a výplňové slová ($F1 = 0,750$) presne dosahujú akceptačné prahy. Pod prahom zostávajú tri dimenzie: nedostatočná gestikulácia ($F1 = 0,647$), otočenie chrbtom ($F1 = 0,400$) a nadmerná gestikulácia ($F1 = 0,417$). Nízke výsledky gestikulácie reflektujú subjektívnu povahu hranice medzi prirodzeným a nedostatočným pohybom, kde nastavený prah rýchlosti zápästia (0,18) zle generalizuje na iné snímacie podmienky. Nízky recall otočenia chrbtom (0,400) je spôsobený jedným testovacím videom, kde sa prezentujúci otáčal pri pohľade na plátno v nepravidelných, krátkych intervaloch, ktoré neprekročili minimálnu dobu trvania udalosti.

6.1.4 Analýza chýb

Výplňové slová — falošne pozitívne detekcie: Neverbálne zvuky (kašeľ, vzdych) sú príležitostne klasifikované ako *uhh*. Minimálna trvacia podmienka na

ozvučený segment čiastočne obmedzuje tento efekt.

Očný kontakt — falošne negatívne detekcie: Pohľady na poznámky umiestnené pod kamerou nie sú spoľahlivo detekované — yaw uhol zostáva v rámci zóny publika, pretože hlava sa nakláňa, nie otáča. Detekcia by vyžadovala kombináciu yaw a pitch uhla s nižším pitch prahom.

Očný kontakt — otočenie chrbtom, nízky recall: Krátkodobé otočenia (menej ako minimálna doba trvania udalosti) nie sú zachytené. V testovacích scenároch, kde prezentujúci opakovane nakukol na plátno, systém tieto epizódy prehliadol, čo znížilo recall na 0,400.

Monotónnosť — falošne pozitívne detekcie: Tiché úseky reči (neozvučené snímky) môžu byť mylne označené ako monotónne, ak RMS energia klesne pod prah pred filtrovaním pomocou `valid_mask`. Video V11 (priemerná konverzácia) vygenerovalo 11 sekúnd falošne pozitívnych detekcií, čo výrazne znížilo priemernú presnosť (0,567) bez dopadu na agregátne F1 (počítané len z videí s referenčnými udalosťami).

Gestikulácia — variabilita a nízke F1: Prahová hodnota rýchlosti zápästia 0,18 je optimum na ladiacej sade. Pri inej vzdialenosti kamery alebo zmene perspektívy sa absolútne hodnoty normalizovaných súradníc menia. Detekcia nadmerného pohybu rúk ($F1 = 0,417$) má dodatočnú príčinu: hranica medzi expresívnou a nervóznou gestikuláciou je ťažko definovateľná bez subjektívneho hodnotenia, a teda ani anotácia ground truth nie je jednoznačná. Odporúčaním pre budúci vývoj je kalibrácia prahov relatívne voči výške prezentujúceho v záznamu.

Kalibrácia na malej vzorke: Kľúčovým systémovým obmedzením je, že všetky prahy detektorov boli kalibrované na malej sade vlastnoručne nahratých kalibračných videí. Tým pádom môžu byť hodnoty optimalizované pre konkrétne snímacie

podmienky (kamera, osvetlenie, vzdialenosť, pozadie), v ktorých boli tieto videá nakrúcané, a nemusia dobre generalizovať na iné podmienky. Pre spoľahlivejšie prahy by bolo potrebné kalibrovať systém na rozsiahlom a rôznorodom datasete prezentácií od viacerých prezentujúcich v rôznych prostrediach.

Kvalita a vzdialenosť mikrofónu: Výsledky akustickej analýzy (hlasitosť, monotónnosť, výplňové slová) sú priamo závislé od kvality a vzdialenosti mikrofónu od prezentujúceho. Slabý mikrofón alebo väčšia vzdialenosť spôsobuje, že signál je zašumený a energia hlasu nízka, čo vedie k falošne pozitívnym detekciám tichého hlasu a sťažuje správnu identifikáciu ozvučených snímkov pre analýzu pitch. Hoci normalizácia pomocou dBFS a adaptívne prahy tieto efekty čiastočne kompenzujú, kompletne ich eliminovať nie je možné bez dodatočnej kalibrácie na konkrétnom záznamovom zariadení.

6.2 Pilotná štúdia účinnosti

Pilotná štúdia overuje, či opakované používanie systému koreluje s merateľným zlepšením prezentačných schopností. Štúdia bola realizovaná s $N = 4$ dobrovoľníkmi počas jedného pracovného týždňa (5 sedení, jedno denne).

Parameter	Hodnota
Počet účastníkov	4
Počet sedení / účastník	5
Frekvencia sedení	1 × denne
Dĺžka prezentácie	~1 minúta
Téma	Rovnaká pre všetky sedenia jedného účastníka
Trvanie štúdie	1 týždeň

Tabuľka 6.3: Parametre pilotnej štúdie

Každé sedenie pozostávalo z nasledujúcich krokov: účastník nahrá prezentáciu mobilnou aplikáciou, systém vygeneruje analýzu a hodnotenie, účastník si preštuduje

spätnú väzbu a na ďalší deň postup opakuje s rovnakou témou.

6.2.1 Výsledky — objektívne metriky

Účastník	S1	S2	S3	S4	S5	Δ	% zmena
P1	61	65	72	76	75	+14	+23 %
P2	85	87	86	80	85	0	0 %
P3	71	88	90	90	87	+16	+23 %
P4	60	77	76	77	79	+19	+32 %
Priemer	69,3	79,3	81,0	80,8	81,5	+12,3	+20 %

Tabuľka 6.4: Trajektória celkového skóre naprieč sedeniami (S1–S5)

Taja zo štyroch účastníkov zaznamenali merateľné zlepšenie celkového skóre. Priemerný nárast bol +12,3 bodov (+20 %) za 5 sedení. Najvýraznejší pokrok dosiahol P4 (+32 %), ktorý začínal s veľmi nízkym skóre plynulosti (6 bodov z 100), čo vytvorilo veľký priestor na zlepšenie. P3 zaznamenal náhly skok už v druhom sedení (71 $\rightarrow$ 88), čo naznačuje rýchlu adaptáciu na spätnú väzbu systému.

Výnimkou je P2, ktorého celkové skóre ostalo na vstupnej úrovni (85 $\rightarrow$ 85). Príčinou je štruktúra hodnotiaceho modelu: P2 mal od začiatku vysoké skóre hlasu (94) a plynulosti (100), kde ďalší rast bol obmedzený. Jeho dimenzia tela vzrástla z 32 na 62 (+30 bodov), avšak táto dimenzia má váhu len 9 %, čo na celkovom skóre zanechalo minimálnu stopu. Táto situácia ilustruje dôležitý aspekt váhového modelu — nízka váha pohybu tela odráža výsledok výskumnej štúdie, no môže pôsobiť demotivujúco pre účastníkov, ktorých hlavnou slabinou je práve táto dimenzia.

Zmeny po jednotlivých dimenziách ukazujú, kde bol pokrok najpriamejší:

Účastník	Δ hlas	Δ plynulosť	Δ oč. kontakt	Δ telo
P1	+9	+21	+12	+23
P2	+1	-10	+1	+30
P3	+12	+30	+5	+32
P4	-2	+60	+7	+25
Priemer	+5	+25	+6	+28

Tabuľka 6.5: Zmena skóre po dimenziách (S5 – S1)

Napriek nízkej váhe dosiahla dimenzia tela najväčší priemerný nárast (+28 bodov), čo naznačuje, že práve pohyb bokov a gestikulácia sú oblasti, kde účastníci po obdržaní spätnej väzby dokážu rýchlo zareagovať. Plynulosť reči vzrástla priemerne o +25 bodov, no s veľkou variabilitou: P4 zlepšil plynulosť o 60 bodov (z 6 na 66), zatiaľ čo P2 o 10 bodov poklesol (zo 100 na 90), čo zodpovedá prirodzenej variabilite výskytu výplňových slov medzi sedeniami.

6.2.2 Výsledky — subjektívne hodnotenie

Po každom sedení účastníci hodnotili tri tvrdenia na Likertovej škále 1–5 (priemery naprieč všetkými štyrmi účastníkmi):

Otázka	S1	S2	S3	S4	S5
Spätná väzba mi pomohla identifikovať slabiny	3,8	4,0	4,2	4,3	4,4
Cítim, že sa moje zručnosti zlepšujú	3,4	3,6	3,9	4,1	4,3
Spätná väzba bola zrozumiteľná a konkrétna	4,0	4,1	4,2	4,3	4,3

Tabuľka 6.6: Priemerné Likert hodnotenia (1–5) per sedenie

Všetky tri otázky vykazujú rastúci trend. Subjektívny pocit zlepšenia rastie najrýchlejšie — účastníci vnímali pokrok výraznejšie v neskorších sedeniach, keď spätná väzba začala byť konkrétnejšia a zmeny merateľné.

6.2.3 Záver štúdie

Traja zo štyroch účastníkov zaznamenali merateľné zlepšenie celkového skóre počas jedného týždňa. Priemerný nárast bol +12,3 bodov (+20 %). Dimenziálna analýza ukazuje, že telo a plynulosť reči sú oblasti s najväčším potenciálom rýchleho zlepšenia po obdržaní cielenej spätnej väzby.

Výsledky naznačujú, že systém má potenciál slúžiť ako tréningový nástroj. Je nevyhnutné uznať obmedzenia: pri $N = 4$ bez kontrolnej skupiny nie je možné oddeliť efekt systému od prirodzeného zlepšenia opakovaným prezentovaním rovnakej témy. Záver netvrdí príčinnú súvislosť, ale naznačuje smer pre ďalší výskum s väčšou vzorkou.

Záver

Cieľom tejto diplomovej práce bolo navrhnúť a implementovať inteligentného asistenta pre tréning prezentačných schopností, ktorý by využíval moderné technológie na automatickú analýzu nahraných prezentácií a poskytoval používateľom konkrétnu spätnú väzbu.

7.1 Zhrnutie dosiahnutých výsledkov

Systém bol navrhnutý ako sada mikroslužieb, pričom každá pokrýva rozdielne detekcie negatívnych javov. Implementované boli nasledujúce komponenty:

- **Spracovanie vstupných dát** — extrakcia kľúčových bodov tela pomocou MediaPipe Pose, normalizácia a resampling audia, transkripcia reči pomocou OpenAI Whisper.
- **Vizuálna analýza** — detekcia očného kontaktu cez výpočet uhlov yaw/pitch hlavy, analýza pohybu bokov a pohybov rúk na základe kinematiky zápästí.
- **Hlasová analýza** — detekcia monotónnosti hlasu algoritmom YIN, analýza hlasitosti cez RMS energiu.
- **Analýza plynulosti reči** — detekcia výplňových slov z transkriptu, segmentácia výskytu pomocou bottom-up algoritmu.
- **Hodnotenie prezentácie** — agregácia čiastkových skóre do celkového hodnotenia s konfigurovateľnými váhami dimenzií.

- **Mobilná aplikácia** — Flutter aplikácia umožňujúca nahrávanie videa, spustenie analýzy a prezeranie výsledkov.

Systém pokrýva celý životný cyklus analýzy: od nahrávania videa cez extrakciu príznakov a detekciu javov až po zobrazenie výsledkov s časovými stopami anomálií.

7.2 Výsledky výskumnej štúdie

Súčasťou práce bola používateľská štúdia ($n = 52$) zameraná na overenie predpokladanej hierarchie dimenzií a vplyvu distribúcie výplňových slov na vnímané hodnotenie. Štúdia priniesla tieto hlavné závery:

- **Hlas dominuje nad vizuálnymi dimenziami.** Viacnásobná lineárna regresia ukázala, že hlas má najvyšší štandardizovaný beta koeficient ($\beta = 0,843$) a štatisticky signifikantne dominuje nad vizuálnymi dimenziami ($t = -5,238$, $p < 0,001$). Predpokladaná hierarchia vizuálne $>$ hlasové nebola potvrdená.
- **Rovnomerne rozložené výplňové slová sú vnímané výrazne horšie.** Respondenti hodnotili prezentáciu s rovnomerne rozloženými výplňovými slovami priemerne o 1,8 bodu horšie ako tú istú prezentáciu s rovnakým počtom výplňových slov sústredených v jednom bloku ($t = 5,492$, $p < 0,001$, $d = 0,871$); takto hodnotilo 40 z 52 respondentov (76,9 %).

Tieto zistenia boli priamo zapracované do hodnotiaceho modelu. Aktualizácia váh dimenzií z pôvodných odhadov na hodnoty odvodené z regresných koeficientov zvýšila Spearmanovu koreláciu modelu s ľudskými hodnoteniami z $\rho = 0,600$ na $\rho = 0,829$ ($p = 0,042$). Model v3 ďalej rozšíril hodnotenie plynulosti o penalizáciu za rovnomernú distribúciu výplňových slov.

7.3 Obmedzenia systému

Napriek dosiahnutým výsledkom má systém niekoľko identifikovaných obmedzení:

- **Kalibrácia absolútnych hodnôt skóre.** Systém systematicky nadhodnocuje kvalitu prezentácie o cca 24 bodov v porovnaní s ľudskými hodnoteniami. Príčinou je, že systém deteguje len merateľné technické javy, zatiaľ čo ľudia vnímajú prezentáciu holisticky — vrátane nervozity, dikcií a obsahu.
- **Detekcia očného kontaktu.** Prahové hodnoty zóny publika sú nastavené konzervatívne a môžu viesť k falošne pozitívnej detekcii očného kontaktu pri pohľade do poznámok pod kamerou. Kalibrácia prahov zostáva výzvou pre ďalší vývoj.
- **Jazyková závislosť transkripcie.** Zoznam výplňových slov je momentálne nastavený pre slovenský jazyk. Rozšírenie na iné jazyky si vyžaduje manuálnu konfiguráciu.
- **Statická analýza.** Systém pracuje výhradne so záznamami prezentácií. Analýza v reálnom čase nie je v súčasnosti podporovaná.

7.4 Možnosti ďalšieho rozvoja

Na základe skúseností z implementácie a obmedzení systému identifikujem tieto prioritné smery ďalšieho vývoja:

- **Kalibrácia hodnotenia.** Zbieranie spätnej väzby od používateľov na konkrétnych nahrávkach by umožnilo tréning korekčnej vrstvy, ktorá by prispôbila absolútne hodnoty skóre ľudskému vnímaniu.
- **Analýza obsahu prezentácie.** Integrácia jazykového modelu by umožnila

hodnotenie štruktúry, zrozumiteľnosti a relevantnosti obsahu.

- **Rozšírenie detekcie výplňových slov.** Automatické rozpoznávanie výplňových slov prostredníctvom jazykového modelu namiesto pevného zoznamu by zlepšilo pokrytie a jazykovú nezávislosť.
- **Analýza v reálnom čase.** Podpora živého streamovania by umožnila okamžitú spätnú väzbu počas nácviku, čo je z pedagogického hľadiska cennejšie ako post-hoc analýza.

7.5 Záverečné zhodnotenie

Práca preukázala, že automatická analýza prezentačných schopností pomocou moderných metód počítačového videnia, spracovania reči a štatistickej analýzy je realizovateľná na bežnom mobilnom zariadení bez špeciálneho hardvéru. Kľúčovým prínosom je prepojenie výskumu so systémovým návrhom — výsledky používateľskej štúdie priamo ovplyvnili váhy hodnotiaceho modelu a viedli k merateľnému zlepšeniu jeho validity ($\rho = 0,829$). Hodnotenie systému (kapitola 6) potvrdilo, že detektory dosahujú F1 nad minimálnymi akceptačnými prahmi a opakované používanie systému koreluje so zlepšením prezentačných skóre o priemerne +20 % za 1 týždeň. Systém tak nepredstavuje len technickú implementáciu, ale aj príspevok k porozumeniu toho, ako ľudia vnímajú prezentačné schopnosti.

Literatúra

- [1] Silvia Maria Alessio. “Sampling of Continuous-Time Signals”. In: *Digital Signal Processing and Spectral Analysis for Scientists: Concepts and Applications*. Cham: Springer International Publishing, 2016, s. 133–152. ISBN: 978-3-319-25468-5. DOI: 10.1007/978-3-319-25468-5_4. URL: https://doi.org/10.1007/978-3-319-25468-5_4.
- [2] Leandro Anghinoni et al. “Time series trend detection and forecasting using complex network topology analysis”. In: *Neural Networks* 117 (2019), s. 295–306.
- [3] Zenodo B. McFee. “Librosa 0.11.0”. 2025.
- [4] Juan Pablo Bello et al. “A tutorial on onset detection in music signals”. In: *IEEE Transactions on speech and audio processing* 13.5 (2005), s. 1035–1047.
- [5] Alain De Cheveigné a Hideki Kawahara. “YIN, a fundamental frequency estimator for speech and music”. In: *The Journal of the Acoustical Society of America* 111.4 (2002), s. 1917–1930.
- [6] Suresh R Devasahayam. “Digitization and discrete systems: sampling and quantization”. In: *Signals and Systems in Biomedical Engineering: Physiological Systems Modeling and Signal Processing*. Springer, 2019, s. 105–133.
- [7] Django Software Foundation. *Django: The web framework for perfectionists with deadlines*. 2024.
- [8] Docker, Inc. *Docker: Accelerated Container Application Development*. 2024.
- [9] Federico Domínguez, Leonardo Eras a Adriana Collaguazo. “Insights on the Distribution of Nonverbal and Verbal Oral Presentation Skills in an Educational Institution”. In: *SN Computer Science* 5.5 (2024), s. 491.

- [10] Emily Duvall et al. “Exploring filler words and their impact”. In: *Schwa. Language & Linguistics* 11 (2014), s. 35–49.
- [11] FFmpeg Developers. *FFmpeg: A complete, cross-platform solution to record, convert and stream audio and video*. 2024.
- [12] Google LLC. *Flutter: Build apps for any screen*. 2024.
- [13] Stephen Haben, Marcus Voss a William Holderbaum. “Time Series Forecasting: Core Concepts and Definitions”. In: *Core Concepts and Methods in Load Forecasting: With Applications in Distribution Networks*. Springer, 2023, s. 55–66.
- [14] Mohammed Hoque et al. “Mach: My automated conversation coach”. In: *Proceedings of the 2013 ACM international joint conference on Pervasive and ubiquitous computing*. 2013, s. 697–706.
- [15] Rebecca Killick, Paul Fearnhead a Idris A Eckley. “Optimal detection of changepoints with a linear computational cost”. In: *Journal of the American Statistical Association* 107.500 (2012), s. 1590–1598.
- [16] Ambika Kirkland, Joakim Gustafson a Eva Szekely. “Pardon my disfluency: The impact of disfluency effects on the perception of speaker competence and confidence”. In: *Proceedings of INTERSPEECH*. 2023, s. 5217–5221.
- [17] David Lapakko. “Communication is 93% nonverbal: An urban legend proliferates”. In: *Communication and Theater Association of Minnesota Journal* 34.1 (2007), s. 2.
- [18] Matthew M Laske. *The Effects of Filler Sounds, Speaker Gender, and Race on Perceived Speaking Effectiveness and Learning Outcomes*. University of Kansas, 2024.
- [19] Yeptain Leung et al. “Speaking fundamental frequencies of adult speakers of Australian English and effects of sex, age, and geographical location”. In: *Journal of Voice* 36.3 (2022), 434–e1.

- [20] Ze-Nian Li, Mark S Drew a Jiangchuan Liu. “Basics of Digital Audio”. In: *Fundamentals of Multimedia*. Springer, 2014, s. 139–181.
- [21] Google LLC. “Pose landmark detection guide”. 2025.
- [22] Albert Mehrabian et al. *Silent messages*. Zv. 8. 152. Wadsworth Belmont, CA, 1971.
- [23] William W Melek et al. “Comparison of trend detection algorithms in the analysis of physiological time-series data”. In: *IEEE transactions on biomedical engineering* 52.4 (2005), s. 639–651.
- [24] Raha Nekoutabar, Fatemeh Sadat Ghaheri a Hamid Jalilvand. “The Effect of Root-Mean-Square and Loudness-Based Calibration Approach on the Acceptable Noise Level”. In: *Auditory and Vestibular Research* 33.4 (2024), s. 361–370.
- [25] Anh-Tuan Nguyen, Wei Chen a Matthias Rauterberg. “Intelligent presentation skills trainer analyses body movement”. In: *International Work-Conference on Artificial Neural Networks*. Springer. 2015, s. 320–332.
- [26] OpenAI. *Whisper: Robust Speech Recognition via Large-Scale Weak Supervision*. 2022.
- [27] Miguel Ramlatchan a Ginger S Watson. “Enhancing instructor credibility and immediacy in online multimedia designs”. In: *Educational Technology Research and Development* 68.1 (2020), s. 511–528.
- [28] Jan Schneider et al. “Presentation Trainer: what experts and computers can tell about your nonverbal communication”. In: *Journal of Computer Assisted Learning* 33.2 (2017), s. 164–177.
- [29] Susan Troncoso Skidmore, John R Slate a Anthony J Onwuegbuzie. “Developing effective presentation skills: Evidence-based guidelines”. In: *Research in the Schools* 17.2 (2010), s. 25–37.

- [30] Jordan Smith. “Unit 32: Presentations—An Overview”. In: *Communication at Work* (2019).
- [31] Benjamin Stone. “Distinguishing high-quality audio: The unique contribution of bit-depth resolution?” In: (2023).
- [32] The PostgreSQL Global Development Group. *PostgreSQL: The World’s Most Advanced Open Source Relational Database*. 2024.
- [33] Timescale, Inc. *TimescaleDB: Time-series data for PostgreSQL*. 2024.
- [34] Julian Treasure. *How to speak so that people want to listen*. 2013.
- [35] Alexander Triassi, Andee Wallace a Sarah Bening. *Public Speaking: Nonverbal*.
- [36] Charles Truong, Laurent Oudre a Nicolas Vayatis. “Selective review of offline change point detection methods”. In: *Signal Processing* 167 (2020), s. 107299.
- [37] Raphael Vallat. “Pingouin: statistics in Python”. In: *Journal of Open Source Software* 3.31 (2018), s. 1026.
- [38] VMware, Inc. *Spring Boot*. 2024.
- [39] Chengyu Wang et al. “Unsupervised time series segmentation: A survey on recent advances”. In: *Computers, Materials, & Continua* 80.2 (2024), s. 2657.
- [40] Benjamin Weiss a Felix Burkhardt. “Voice attributes affecting likability perception.” In: *Interspeech*. 2010, s. 2014–2017.
- [41] Haipeng Zeng et al. “Gesturelens: Visual analysis of gestures in presentation videos”. In: *IEEE Transactions on Visualization and Computer Graphics* 29.8 (2022), s. 3685–3697.
- [42] Ru Zhao et al. “Semi-automated 8 collaborative online training module for improving communication skills”. In: *Proceedings of the ACM on interactive, mobile, wearable and ubiquitous technologies* 1.2 (2017), s. 1–20.

Vyhlásenie o použití nástrojov umelej inteligencie

Týmto vyhlasujem, že počas prípravy a realizácie tejto diplomovej práce boli ako podporné nástroje použité ChatGPT (OpenAI) a Claude (Anthropic). Tieto nástroje boli použité prevažne pre štylistické úpravy textu, ladenie chýb, ladenie algoritmov a všeobecnú podporu pri programovaní riešenia.

Nesiem plnú zodpovednosť za odborný obsah, návrh a implementáciu systému ako aj za konečnú podobu tejto práce.

OpenAI (2026), ChatGPT — podpora pri jazykových a štylistických úpravách textu

Anthropic (2026), Claude — podpora pri jazykových a štylistických úpravách textu, podpora pri programovaní a ladení kódu